



内容列表可在科学直接获得

应用能量

期刊主页: www.elsevier.com/locate/apenergy

一种针对钻泵故障诊断的混合深度学习模型

郭俊宇^{a, b, d, *} 杨玉莱^{a, b}、何丽^{c, d, **} 王江^{a, b} 唐爱安^e、戴伟山^e、黄邦奎^e^a 西南石油大学教育部油气设备重点实验室, 成都, 四川, 610500^b 西南石油大学机电工程学院, 四川, 610500, 中国^c 利物浦约翰摩尔大学工程学院, 利物浦, 拜伦街3号, L3 3AF, 英国^d 葡萄牙里斯本大学, 印度高等海洋科学研究所, 海洋技术和海洋工程中心 (CENTEC)^e 四川宏华石油设备有限公司, 四川广汉, 邮编: 618300

H I G H L I G H T S

提出了一种新型的智能钻泵故障诊断方法WCCN-BiLSTM。

构造了WCCN, 用于降噪和信号的特征提取

WCCN中嵌入的CBAM模块增强了信道和空间维度的特征表示。

通过钻泵数据的不同工况, 验证了模型的诊断能力和泛化能力。

A R T I C L E I N F O

关键词:

钻井泵

故障诊断

CBAM网络双向长-短期记忆

A B S T R A C T

提出了一种用于钻泵智能故障诊断的小波核网卷积块注意模块bilstm诊断方法。首先采用随机森林法确定能反映钻井泵故障特性的目标信号。据此, 构建了WaveletKernelNetConvolutional块注意模块网, 基于信号进行降噪和故障特征提取。在小波网络-CBAM中嵌入的卷积块注意模块调整了权重, 增强了信道和空间维度的特征表示。最后, 引入了双向长-短期记忆的概念, 以提高模型处理时间序列数据的能力。在构建网络的基础上, 利用贝叶斯优化算法对理想的超参数进行确定和微调, 从而确保网络达到最优性能水平。利用混合深度学习模型, 对一个实际的五缸钻井泵进行了准确的故障诊断, 结果验证了该模型的适用性和可靠性。两组比较实验验证了该方法的优越性。此外, 还通过领域自适应实验验证了该模型的可推广性。该方法通过对工业设备提供准确、可靠的故障诊断, 有助于油气行业的安全生产。

1. 介绍

石油和天然气仍然在为世界提供动力, 尽管对可再生能源的需求激增和发展, 如风能、水电、太阳能、核能等[1-3]。与陆上能源生产设备不同, 钻井设备在地下或海底运行, 代表着可达性低, 工作条件恶劣, 对操作人员的干预有限,

维护人员, 和其他利益相关者, [4-6]。

钻井泵是钻井装置中风险最大的部件之一, 通过高压管道和钻杆中心井孔输送到井底, 保持井眼清洁, 支持钻头润滑和冷却, 将钻头产生的岩屑排放到地表[7]上。如果不能及时识别钻井泵中的故障, 可能会导致设备损坏, 造成现场作业延误, 并造成财产损失。钻井泵的故障诊断为

*通讯作者: 西南石油大学机电工程学院, 成都, 四川, 610500, 公关中国。 **通讯作者: 利物浦约翰摩尔大学工程学院, 利物浦, Byrom街3号, L3 3AF, 英国。

电子邮件地址: jyguo@163.com (J. 郭), 他。 li@centec.特克尼科.ulisboa.pt (H. 列支敦士登)

<https://doi.org/10.1016/j.apenergy.2024.123773>

2023年10月23日收到; 2024年4月12日收到表格; 2024年6月20日接受

2024年6月26日在线提供

作者: 0306-2619/©2024。爱思唯尔有限公司出版。这是一篇在CC BY许可下的开放获取的文章(<http://creativecommons.org/licenses/by/4.0/>)。

命名法	
缩写	
CNN	卷积神经网络
CWConv	连续小波卷积
CBAM	卷积块注意模块
WCCN	万向网-CBAM网
BiLSTM	双向长-短期记忆
射频	随机森林
递归神经网络	循环神经网络
激光扫描跟踪法	长短期记忆
格勒乌波	闸门经常性装置
双向卷积LSTM	贝叶斯优化
mdr, 硫	多尺度深度剩余学习
氰酸盐	多尺度卷积神经网络
中心	稀疏卷积网络
	连续小波变换
	每分钟中风次数

对石油、天然气和其他能源钻井作业的重要性。根据现场数据，上述装置在陆上或海上生产过程中钻井装置故障占很大一部分。其根本原因可以追溯到 [8, 9]：(i) 有害的工作条件，包括磨料和腐蚀性泥浆、高强度工作需求、地下或海上钻井作业不确定；(ii) 维修可达性低，说明轻微故障可能导致未额定生产，只能在钻井作业完成后进行固定。因此，这种严重依赖钻井泵状态意识的装置的长期，紧迫的紧急需求。然而，它仍然是基于对经验丰富的操作人员的主观判断。

具体来说，有经验丰富的操作人员根据钻井过程中产生的声音来识别钻井泵的健康状态。可用的信息由手动识别在某种程度上受限于只提供一个预先判断故障的存在和严重性 [10]，更详细和实际的决策辅助信息如位置和剩余的有用的操作时间仍然无法根据手动识别方式。因此，从业者正在寻求自动状态意识方法或有用的工具，以支持设备的最佳和可靠的操作，如传感器和适用的方法，如深度学习模型。

本研究提出了一种新的钻井泵故障诊断框架，称为WCCNBiLSTM。该框架的核心是小波内核-CBAM Net (WCCN) 模型，它与双向长-短期内存 (BiLSTM) 体系结构无缝集成。利用该方法对一个五缸钻井泵进行了准确的故障诊断。总体上，该方法有助于油气行业的安全生产，有利于工业设备的准确、可靠的故障诊断。

本文的其余部分的结构如下：第2节概述了当前最先进的技术，并提出了关于问题陈述的学术观点。第3节详细说明了所采用的方法。第四节介绍了钻井泵及其故障诊断过程。最后，第5节给出了结论。

2. 最新的状态和问题的陈述

2.1. 2数据驱动故障诊断

2.1.1. 从CNN到BiLSTM

传统的数据驱动的故障诊断方法，如机器学习，已经被实现来解决现实世界中的工程问题 [11]。例如，Chen等人。[12]采用分层机器学习方法，采用双层模型来检测齿轮箱故障。李等人。[13]介绍了一种用于诊断液压泵故障的极端学习机技术，特别是解决了轴向活塞泵中复杂故障诊断的挑战。与此同时，刘等人。[14]提出了一种增强的基于机器学习的多相驱动系统故障诊断方法。Lan等。[15]应用信号处理技术和极值学习机，构建了轴向活塞泵拖鞋磨损故障诊断的智能网络。然而，这些方法存在严重依赖现有经验和知识等缺点，在提取深度和不明显的失效特征 [16, 17] 方面存在困难。

近年来，故障诊断领域见证了向深度学习技术的重大转变，解决了前面提到的 [18] 等传统方法固有的局限性。这一趋势归因于卷积神经网络 (CNN) 的采用，该网络通过使用共享权重 [19] 的多层来识别空间特征和结构。Kumar等人。[20]介绍了一种利用CNN增强的方法，在代价函数中集成基于熵的散度函数，利用分析小波变换处理的声图像，有效识别离心泵的缺陷。同样，唐等人。[21]引入了一种增强的CNN模型，其学习速率适用于液压活塞泵故障诊断，有效地利用振动、压力和声音信号来提高检测精度。为了实现钻井泵的故障诊断，Li等人。[22]开发了一种基于cnn的故障诊断方法，该方法利用一种创新的扩展操作，将一维振动信号转换为增强的三维图像。唐等人。[23]利用广义S变换将原始振动信号转换为时频图像数据集，然后应用CNN模型对钻井泵进行故障诊断。与CNN类似，递归神经网络 (RNN) 是一个用于模式识别、特征提取和序列建模的强大工具。RNN以其循环连接为特征，可以处理可变长度的序列，并在每个时间步长传递隐式状态，这一功能使它们能够有效地捕获这些序列 [24] 中的时间信息。王等人。[25]开发了一种基于RNN的风力发电系统多故障诊断方法，利用风速和转子转速等30个特征参数作为输入。然而，在处理长序列输入时，rnn面临着梯度消失或爆炸的挑战。为了应对这一问题，霍克雷特和施米德胡伯 • [26]开发了长短期记忆 (LSTM) 网络，该网络将记忆单元集成到隐藏层中，增强了RNN。LSTM利用门控单元来控制信息流，允许模型有效地学习长期的依赖关系。Bie等。[27]开发了一种利用LSTM的往复泵故障诊断方法，并通过改进的仿真算法进行了改进。该方法利用振动信号，有效地提取故障特征进行分类。此外，Chung等。[28]引入了门控循环单元 (GRU) 网络，这是对LSTM结构的一种优化。这种方法简化了连接架构，减少了可训练参数的数量，从而提高了训练效率，同时保持了网络内的内存功能。苗等人。[29]开发了一种基于GRU的行星齿轮箱故障诊断方法，并通过退出技术进行了改进。该方法以振动信号为输入，侧重于保持识别能力，快速适应新的故障类型。BiLSTM是LSTM的高级迭代，熟练地捕获序列数据信息，解决了遥远序列位置的影响

目前有效解决了长期依赖问题。利用具有注意机制增强的集成BiLSTM网络，Han等人。[30]设计了一种针对可变制冷剂流（VRF）系统的鲁棒故障诊断方法，在各种条件下实现了较高的精度和有效的泛化。表1详细介绍了上述具有代表性的故障诊断方法，这些方法都基于单一网络。

2. 1. 2. 从单一的网络到它们的组合

单一网络在处理故障诊断问题时不足以应用于大类别数据的实际工程设备[31, 32]：(i) 很难代表复杂的关系和特征，不同类型的问题，有时需要不同类型的网络，单个网络无法满足需求等需求；(ii) 应用于复杂工程案例时功能有限，需要融合融合；(iii) 阻碍模块化设计和模型功能扩展。因此，提出了组合网络来消除上述单个网络所带来的缺点。李等人。[33]介绍了一种结合CNN和GRU来诊断齿轮点蚀故障的方法。该方法显示了令人印象深刻的故障诊断精度，即使在处理有限的样本量时，也能达到98%。王等人。[34]和Liao等人。[35]利用CNN提取局部特征，利用GRU获取全局特征和动态信息。张等人。[36]利用CNN提取采集到的信号特征，然后访问LSTM对特征进行建模，获得较高的故障诊断精度。你等人。[37]推荐了一种结合CNN、BiLSTM和AM的方法，通过滚动轴承数据验证了该模型的鲁棒性和有效性。Quang等。[38]建立了CNN-LSTM-AM模型，通过学习映射权重和参数来提高故障检测的准确性，并对异常状态进行预警和故障检测，并在监控和数据采集（SCADA）数据上进行了验证。王等人。[39]在模型中加入了WKN，从而在处理信号噪声的同时减少了模型的参数。黄等人。[40]通过CBAM对信号进行自适应特征细化，实现多分类识别任务。徐等人。[41]提出了一种结合BiLSTM模型的多尺度CNN，解决了智能方法在故障诊断中外推能力不足的问题，提高了在复杂工作条件下的泛化性能。许多

Table 1
单个网络在故障诊断中的应用。

参考资料	模型	对象	使用的信号	优点
库马尔 以及其他 人 [20]	中心体	离心的 泵	声学	将输入信号转换为图像
唐等人。 [21]	中心体	液压的 活塞泵	振动 +Pressure + 声音	将输入信号转换为图像
李等人。 [22]	中心体	钻井泵	振动	信号扩展操作
唐等人。 [23]	中心体	钻井泵	振动	广义S 变换
王 以及其他 人 [25]	递归神经 网络	风力涡轮机	风速+转子转速 +发电机转速	多功能 输入
Bie等。 [27]	激光扫描 跟踪法	往复式泵	振动	信号去噪
苗等人。 [29]	格勒乌 变速箱	行星 变速箱	振动	样本量小
韩等人。 [30]	BiLSTM	VRF系统。	热数据 +Frequency 度量标准 +Electrical 信号	增强的可解释 性

学者们将AM引入深度学习模型，以提高特征表达能力和故障诊断精度[42, 43]。表2列出了该字段中的代表性模型。

. 2. 2. 有问题的陈述和贡献

钻井泵是一种特殊的设备，特别是在故障特征和故障诊断方面。关于钻井泵故障诊断的文献较少，但其可靠的运行对钻井工程具有重要意义，说明钻井泵的智能故障诊断是一项具有挑战性的任务，但是迫切需要的。更重要的是，在复杂和动态的运行环境中，使用传感器的钻井泵收集的信号不可避免地会包含噪声。如果不减少，这种干扰可能会破坏智能故障诊断任务。这是因为人工神经网络可能会将噪声解释为一个与故障相关的特征，这可能会降低诊断的准确性。降低原始信号中的噪声是有效诊断钻井泵故障的关键。然而，所有现有的所有降噪方法都不可避免地一定程度上增加了信号处理时间。这对钻井泵的实时故障诊断提出了一个重大挑战，因为它降低了故障识别的速度，从而导致严重的设备损坏或安全事故。因此，迫切需要一种能够将优越的降噪性能与高效相结合，以适应工程实践要求的故障诊断方法。

然而，现有的最先进的方法在应用于钻井泵的故障诊断时遇到了严重的限制，包括：(1) 大多数方法使用振动信号来表征健康状态。然而，与其他设备相比，钻井泵具有不同的失效模式和失效行为。因此，有必要确定能够更好地反映其健康状态的信号；(2) 钻井泵在恶劣、不确定和不可预测的环境中运行，这对现有方法的降噪能力提出了挑战。为此，本文提出了一种方法

Table 2
组合网络在故障诊断中的应用。

参考资料	模型	对象	使用的信号	优点
李等人。 [33]	克恩格鲁	齿轮	声学+ 摆动	网络 组成
王 以及其他 人 [34]	克恩格鲁	冷却系统	温度+压力	网络 组成
廖等人。 [35]	克恩格鲁	水力发电装置	摆动	网络 组成
张 以及其他 人 [36]	CNN- 激光扫描跟 踪法	液体火箭发动 机	压力+ 权力	仿真数据
你等人。 [37]	CNN- BiLSTM	滚动轴承	摆动	网络 组成
湘语 以及其他 人 [38]	CNN- LSTM -AM	风轮机	温度+功率	网络 组成
王 以及其他 人 [39]	WKN- BiLSTM-	滚动轴承	摆动	信号去噪
黄 以及其他 人 [40]	AM CNN- CBAM-	纤维振动 信号	摆动	好的 一般化
徐等人。 [41]	MSCNN- BiLSTM	风轮机 关系	确认 摆动	能力 良好的泛化能 力
杨等人。 [42]	MBiGRU- AM	关系	摆动	AM介绍
你等人。 [43]	BiLSTM- SCN- 卡巴姆	滚动支座	摆动	良好的泛化能 力

MDRL：多尺度深度残差学习；MSCNN：多尺度卷积神经网络；硫氰酸盐：稀疏卷积网络

小波网-CBAM网(WCCN)模型结合BiLSTM为基础,建立了钻井泵的故障诊断框架,即WCCNBiLSTM。具体来说,WCCN模型包含了WKN和CBAM模块。在这个框架中,WKN模型无缝地将降噪功能集成到网络计算中。这种集成消除了单独信号处理的需要。相反,该模型自动学习并应用降噪函数,绕过额外的降噪步骤,从而加速计算速度。同时,CBAM增强了噪声信号在信道和空间维度上的特征表示,从而提高了学习和识别关键特征的能力。接下来的

因此,采用BiLSTM模块进一步增强了关键信号特征的表示,并进行了序列建模,促进了高效和准确的故障诊断。本文的贡献包括:

(i) 根据随机森林(RF)模型确定能够最佳表征钻井泵故障的信号。

(ii) 创建一个与BiLSTM相结合的WCCN网络

对时间序列数据的降噪和特征提取。

总之,该方法有助于油气行业的安全生产,有利于企业准确、稳健的工业故障诊断




图1. 基于WCCN-BiLSTM的故障诊断方法的框架。

设备

3. 基于WCCN-BiLSTM的故障诊断方法

3.1. 3 WCCN-BiLSTM

本文提出了一种新的钻泵故障诊断方法介绍了WCCN-BiLSTM。WCCN采用连续小波卷积层（CWConv）和标准卷积层来降低原始信号中的噪声，便于基本特征提取。然后采用卷积块注意模块（CBAM）来增强其在通道和空间维度上的特征表示。这种增强提高了对数据信号内基本特征的关注，同时减少了不相关特征的影响。最后，利用BiLSTM模型最终计算特征向量。计算后，将序列数据通过输出层，得到信号识别结果。利用贝叶斯优化（BO），对模型参数进行优化，以达到最优的模型性能。此外，批归一化的加入有效地防止了模型过拟合。基于WCCN-BiLSTM网络的故障诊断框架方法如图所示。1，以下步骤见表3：

步骤1：采集对钻井泵有不同损坏程度的监测信号，并通过射频频法选择最能描述钻井泵故障的监测信号。

步骤2：规范化监测信号，并对样本、数据集和标签进行划分。

步骤3：使用贝叶斯优化来确定WCCN-BiLSTM模型的最优超参数集。

步骤4：使用编译的钻井泵数据集训练和验证WCCN-BiLSTM模型。

步骤5：进行烧蚀实验，评估模型中各模块的效果。通过对比实验，验证了该模型的故障诊断能力。

步骤6：进行领域自适应实验，评估模型在不同工作条件数据集上的泛化能力。

3.2. 3 万向网-CBAM网

CNN在剩余生命预测和故障诊断[44 - 46]方面取得了成功。典型的CNN网络包括输入层、卷积层、池化层、全连接层和输出层。输入层对多维数据进行归一化，并将学习数据输入CNN，以保证操作效率和学习性能[47, 48]。卷积层通过卷积和使用非线性激活函数来生成特征。卷积后，激活函数对每个卷积的输出对数进行非线性变换，目的是增强在另一个空间中线性不可分的多维特征的线性可分性。CNN无法处理原始信号中的噪声，也缺乏令人满意的可解释性。为此，开发了WKN并应用于故障诊断[49]。图2说明了WKN修改了标准的CNN

表3

WCCN-BiLSTM网络的程序。

算法1：所提出的方法。

输入：WCCN-BiLSTM，具有BO选择的最佳超参数；钻泵数据集；

数据预处理：监测信号的选择；信号的标准化；

对于时代= 1, 2, ..., 时代做：

数据通过WCCN通道进行降噪和特征提取，然后进行特征增强；

使用BiLSTM通道对WCCN信道输出的数据进行特征向量操作；

获得WCCN-BiLSTM输出；

采用Adam算法进行优化和减少训练误差；

最后部分

输出：钻井泵故障诊断

用连续小波卷积层代替其第一个卷积层。这种适应能力使WKN具有增强的降噪能力。此外，WCCN建立在WKN奠定的基础上，在模型中加入了一个CBAM。这种集成使WCCN能够更有效地专注于关键特性。

与CNN相比，WCCN在第一个卷积层前后添加了CWConv层和CBAM，并保留了第一个卷积层，与WKN添加了CBAM。CWConv层包含具有不同尺度和平移参数的小波核，并使用由两个可学习参数定义的预定义函数进行卷积。具体来说，CWConv层被定义为：

$$h = \psi_{u,s}(t) * x \quad (1)$$

其中， $\psi_{u,s}(t)$ 表示表示CWConv层结果的预定的超函数，其平移和缩放参数的更新为：

$$\begin{aligned} \delta_{uk} &= \frac{\partial H}{\partial u_k} \frac{\partial H}{\partial z_k} \frac{\partial H}{\partial h_k} \frac{\partial H}{\partial \psi_{u,s}^k} \frac{\partial H}{\partial u_k} \\ \delta_{sk} &= \frac{\partial H}{\partial s_k} \frac{\partial H}{\partial z_k} \frac{\partial H}{\partial h_k} \frac{\partial H}{\partial \psi_{u,s}^k} \frac{\partial H}{\partial s_k} \end{aligned} \quad (2)$$

$$\begin{cases} u_k = u_k - \eta \delta_{uk} \\ s_k = s_k - \eta \delta_{sk} \end{cases} \quad (3)$$

式中， ∂ 为导数算子， $\psi_{u,s}^k$ 表示长度为L，S的层的第k个小波核 k 和 u_k 分别表示比例尺参数和平移参数。具体来说， u 和 s 通过减去学习率 η 和梯度 δ 来更新。

CBAM是一个轻量级的通用模块，通过引入通道注意和空间注意[50]来提高网络的表征和泛化能力。在WCCN框架中，卷积层首先处理信号，捕获与时间相关的特征。信道注意机制通过全局池化和一个全连接层对每个信道进行评估，形成一个信道注意图。然后将此图应用于原始特征图，以有选择性地增强或抑制特定的通道特征。接下来，空间注意成分通过对调整后的特征图进行平均和最大池化，生成序列注意图。这些结果沿着通道维度连接，通过卷积层进行处理。激活后，该地图将调整特征地图上的每个时间点的突出度。如图所示。3。

在CBAM框架内，输入特征在信道注意模块中进行处理，通过平均和最大池化提取高级特征，信道通过多层感知器（MLP）进行压缩和扩展。这个过程增强了网络跨不同通道表示特性的能力。然后，MLP输出的特征被元素求和，并组合为输出的特征向量。通道注意力的计算方法为：

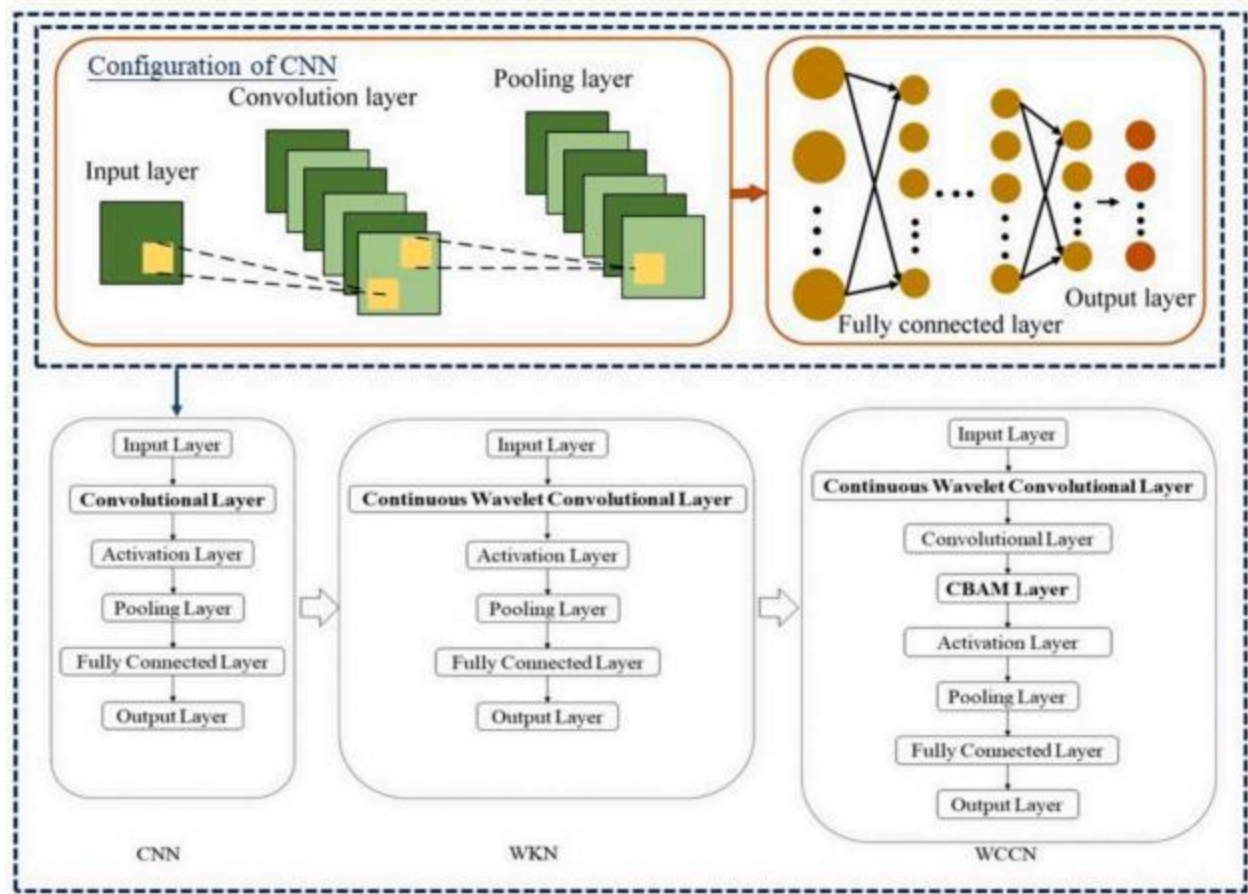


图2. 从CNN发展到WKN和WCCN。

$$M_C(F) = \sigma \left(\text{MLP} \left(\text{AvgPool}(F) \right) \right) + \text{MLP} \left(\text{MaxPool}(F) \right) \quad (4)$$

$$= \sigma \left(W_1 \text{ReLU}(F_{\text{avg}}) + W_2 \text{ReLU}(F_{\text{max}}) \right)$$

其中, $M_C(F)$ 为通道注意权重, σ 为s型激活函数, F 表示特征矩阵。
空间注意模块探讨了特征之间的内在关系, 其计算方法为:

$$M_S(F) = \sigma \left(\text{Conv} \left(\left[\text{AvgPool}(F); \text{MaxPool}(F) \right] \right) \right) \quad (5)$$

$$= \sigma \left(\text{合同组}_{\text{avgmax}}^s \right)$$

其中, $M_C(F)$ 为空间注意权重, 和 $\text{Conv}(\cdot)$, 显示卷积操作。

3.3 BiLSTM

LSTM能够处理和建模时间序列数据, 特别是在解决长期依赖问题[51-53]时, 由不同的门控单元组成, 见图4(a)。输入门确定进入小区状态的新输入信息, 遗忘门确定是否保留先前的信息, 输出门确定在时间片中对网络层的输出。这些机制使LSTM能够管理以前的信息, 并在需要时更新单元格状态。LSTM的计算方法如下:

$$f_t = \sigma \left(W_f [h_{t-1}, x_t] + b_f \right) \quad (6)$$

其中 f_t 和 x_t 表示输出和输入。 σ 反映门通函数, h_{t-1} 是输出。 W_f 和 b_f 是遗忘门的权重和偏差矩阵。

$$i_t = \sigma \left(W_i [h_{t-1}, x_t] + b_i \right) \quad (7)$$

我在哪里 i_t 表示信息输入, W_i 和 b_i 为输入门的权重和偏置矩阵。

$$\tilde{C}_t = \tanh \left(W_c [h_{t-1}, x_t] + b_c \right) \quad (8)$$

在哪里 \tilde{C}_t 是候选记忆细胞。 W_c 和 b_c 为输入门的权重和偏置矩阵。

$$C_t = f_t \times C_{t-1} + i_t \times \tilde{C}_t \quad (9)$$

$$o_t = \sigma \left(W_o [h_{t-1}, x_t] + b_o \right) \quad (10)$$

在哪里 o_t 是信息输出, C_t 表示单元格的当前状态。

$$h_t = o_t \times \tanh(C_t) \quad (11)$$

其中 h_t 表示从两个 o_t 和 C_t 。BiLSTM在两个方向上引入了一个隐藏层LSTM可以更好地捕获时间序列数据中的前后关系。BiLSTM结构如图所示。4(b)。

4. 数据处理

4.1 4钻并泵及数据

本文的实验数据采用HH2400钻井泵试验平台进行实验采集。该数据集是从返回进行修复和测试的钻井组件中获得的

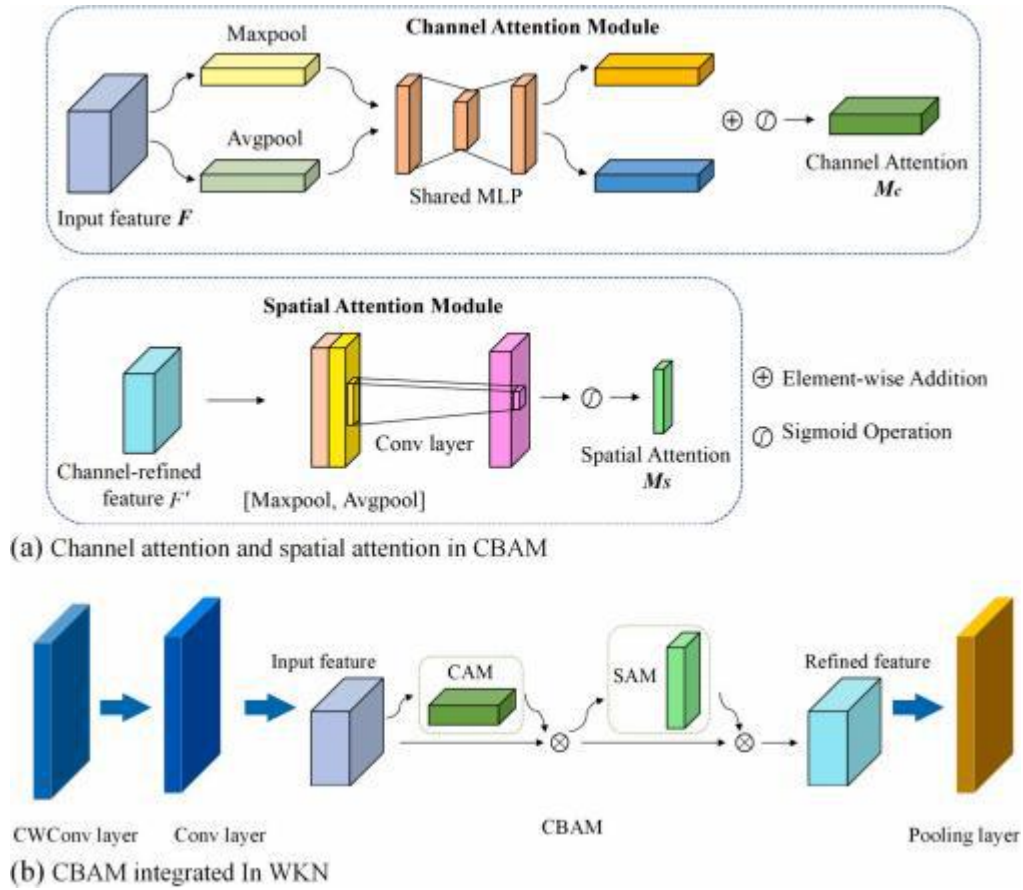


图3. CBMA和WCCN的框架。




图4. LSTM和BiLSTM的结构。

实际操作条件。西门子1500系列PLC用于实现周期为1 ms或更短的实时数据采样。数据采集模块配有压力传感器、应变传感器、振动传感器等。在每个气缸上。HH2400钻井泵及其传感器配置如图所示。5 (a)。仿真信号采用16位精度扩展模拟输入模块，每个模块有8个通道，共3个模块，保证了数据的准确性。在初始处理之后，采样数据存储在PLC内的专用数据存储块 (DB) 中，用于通信传输，便于主机的后续检索。利用以太网作为载体，利用OPC有效地协调PLC数据的快速检索，要求有效的数据检索周期在10 ms范围内。现场工程师根据数据异常情况，建立数据分析规则和算法，确定气缸阀的状态，并将其分为正常运行、轻度损坏、中度损坏、严重损坏等类别。

监测数据来自9组钻井泵，每个泵在四种不同的条件下运行。泵的行程采用不同的频率：每分钟50次行程 (SPM)、90 SPM、110 SPM和130 SPM。阀门状态包括正常、轻微损伤、中度损伤和严重损伤，见图。5 (b)。钻井泵的16个故障列于表4。

在实际钻井作业中，70-130 SPM的泵送冲程是最常见的工作情况。因此，我们选择了具有110个SPM的数据集C来验证WCCN-BiLSTM模型的诊断能力。钻井泵各工况包含16个状态，16万个样本，单个样品包含2048个数据采样点。总样本量以8: 1: 1的比例划分为训练、验证和测试集，分别得到128, 000、16, 000和16, 000个样本。



图5. HH2400钻井泵/ (a) 传感器配置的传感器配置和故障； (b) 故障。

表4
钻井泵数据集的划分。

数据集	泵 中风 (SPM)	状态		标签	编码器
		抽气阀	放电 阀		
A/B/C/ D	50 / 90 / 110 / 130	正常的	次要的 损坏	SNDM1	0
		正常的	中度 损坏	SNDM2	1
		正常的	重的 损坏	SNDH	2
		正常正常		斯坦顿	3
		次要的	次要的	SM1DM1	4
		损坏	损坏	平方米1dm2	5
		次要的	重的	SM1DH	6
		损坏	损坏	SM1DN	7
		中度	次要的	平方米1	8
		损坏	中度	平方米2平 方米	9
		中度	重的	SM2DH	10
		损坏	损坏	SM2DN	11
		损坏	正常的		
		重的	次要的	SHDM1	12
		损坏	中度	SHDM2	13
		重的	重的	SHDH	14
		损坏	损坏		
		重的	正常的	施顿	15
		损坏			

S: 吸入阀, D: 排放阀, N: 正常, M1: 轻微损坏, M2: 中等损坏, H: 严重损坏

4. 2. 监控信号选择

本研究获取了钻井泵的振动、压力、应变、曲轴角度和释放压力信号。
随机森林 (RF) [54]

采用该方法来识别最能反映钻井泵故障特性的监测信号。一个射频树由随机建立的几个不相关的决策树组成。森林中的每棵决策树分别判断一个新的样本来确定其类, 并通过投票得到最终的分类结果。在回归问题中, RF计算所有决策树输出的平均值, 量化特征的重要性。特征的重要性越高, 对模型的准确预测的贡献就越显著, 反之亦然。构建射频的步骤如下:

- 步骤1: 利用随机抽样方法选择自助样本, 构建决策树。
 - 步骤2: 拆分决策树, 直到一个节点中的所有样本都属于同一个类。
 - 步骤3: 使用“带替换”的方法对射频样本进行分类。
- 用于评价分类和回归性能的基尼指数定义为:

基尼= $1 - \sum P_i^2$ (12)

其中, P_i 表示当前节点上数据集中第*i*类样本的比例。
在射频分类中, 所有基尼指数的平均值加权指标为:

$$Q_k = \frac{\sum_{j=1}^n \sum_{i=1}^t D_{格基吉}}{\sum_{k=1}^m \sum_{i=1}^t D_{格基吉}}$$
 (13)

其中, Q_k 表示第*k*个指标在所有指标中的重要性, *m*表示指标总数, 本文为5个, *n*表示决策树的数量, *t*为每个分类树的节点。D_{格基吉}表示第*i*棵树第*j*节点第*k*个指标的基尼指数的下降。

图6显示了信号对钻泵故障诊断的重要性。研究结果表明, 应变信号对捕捉钻井泵故障特性的方法最为有效。选择最相关、最合适的传感器来收集故障诊断信息, 可以简化故障诊断模型的建模, 降低故障诊断模型的建模




图6. 信号在钻井泵故障诊断中的重要性。

数据处理和特征提取的复杂性，有助于实时监测和快速诊断。因此，本研究将应变信号用于钻井泵故障诊断。

5. 实验部分

5.1. 贝叶斯优化模型超参数

贝叶斯优化 (BO) 被广泛认为是机器学习模型[55]中一种高效的超参数选择方法。它的显著优势包括能够以更少的迭代来实现目标，确保更快的收敛。此外，BO对非凸挑战具有特别的鲁棒性，使其成为复杂优化场景中的首选。此外，BO的一个明显优势在于它使用了关于参数的先验信息。该过程包括通过添加新的样本来不断更新目标函数的后验分布，这有助于紧密匹配真实分布。因此，本文采用BO作为选择模型超参数的一种方法，以寻找模型的最优超参数集。

在本研究中，BO过程分为两个不同的阶段。首先，进行了5次初始优化迭代，建立了参数性能的基线模型。这个阶段是必要的，因为贝叶斯优化依赖于先验数据来开始迭代过程。随后，又执行了50次优化迭代。这些迭代都是由贝叶斯优化算法系统设计的，逐步增强和细化参数的选择，以更准确地接近最优解。总共完成了55次迭代，这个数字被认为适合于平衡参数空间的有效探索和计算成本。WCCN-BiLSTM模型的主要超参数由BO进行选择，包括BiLSTM模型的滤波器、核大小、步幅和单位。图7表示网络模型在超参数空间中使用贝叶斯算法选择的每一组超参数集所对应的验证集的精度发生变化的过程。该图包括两个部分：下面的部分详细介绍了超参数值，而上面的部分突出显示了在验证期间使用每个超参数集所达到的峰值精度。在每次迭代中，BO根据之前选择的超参数动态调整下一个超参数选择的值，获得最高的精度。表5综合显示了所探索的超参数值的范围和这一过程的决定性结果。

5.2. 模型评价方法

利用交叉熵损失函数评估了模型的收敛性：

表5

BO中的超参数范围和优化结果[56]。

不	名称	范围	结果
1	过滤	[1, 64]	28
2	内核大小	[1, 64]	33
3	裤子	[1, 16]	12
4	激光扫描跟踪法	[1, 64]	36

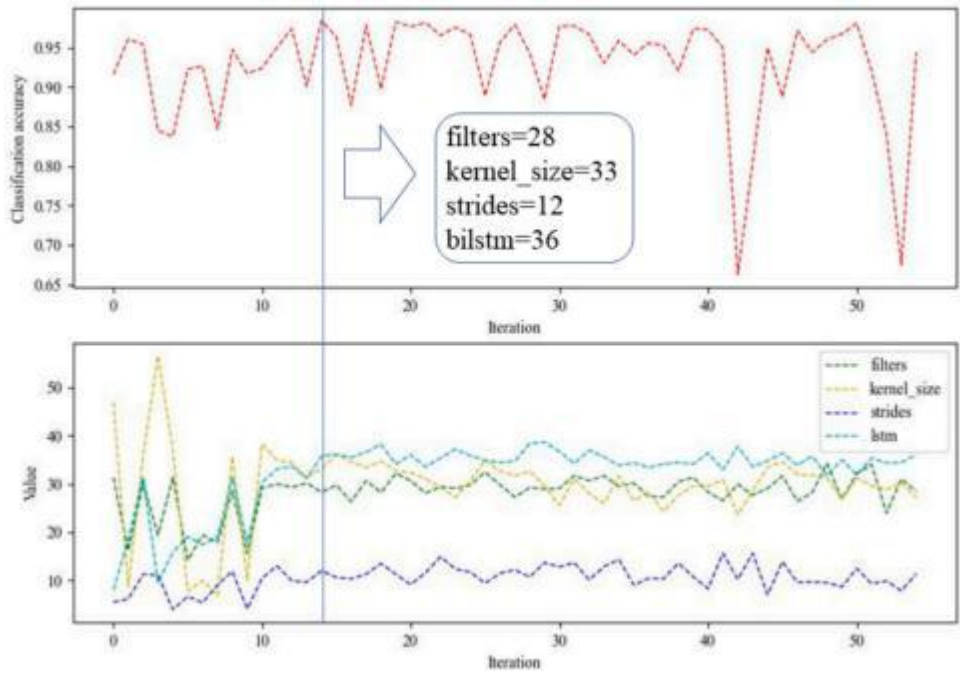


图7. 超参数的训练过程。

$$\text{损失} = -\sum_{i=1}^K y_i \log(p_i) \quad (18)$$

其中 P_i 是标签 i 的概率值，而标签是 i ，它们 i 为1，否则为0。

评估模型的以下标准：准确性、精度、召回率和F1-评分。

$$\text{精度} = \frac{TP + TN}{TP + FP + FN + TN} \quad (19)$$

$$\text{精度} = \frac{TP}{TP + FP} \quad (20)$$

$$\text{召回} = \frac{TP}{TP + FN} \quad (21)$$

$$F1\text{-分数} = \frac{2 * \text{准确率}}{\text{精度} + \text{召回}} \quad (22)$$

其中，TP、FP、FN、TN分别表示真阳性、假阳性、假阴性、真阴性结果的计数。

在等式中（19），精度表示正确预测的样本与样本总数的比值。平衡（20）定义精确度，表示正确预测的阳性样本与实际预测的阳性样本的比例。平衡（21）将召回率定义为被正确预测的阳性样本的比例，以及等式（22）将F1-Score作为模型的综合性能指标。

5.3. 消融实验

为了验证模型的结构，我们设计了烧蚀实验来证明每个单独模块的主动作用。实验以数据集C为中心，对应的泵浦冲程为110SPM。WCCN-BiLSTM模型的训练过程如图所示。8，其中给出了精度和损失值。如图所示，当迭代计数达到50时，就会有明显的收敛趋势。

WCCN、CBAM和BiLSTM模块的消融实验

在计算机1上进行，旨在评估所开发的WCCN-BiLSTM模型中每个模块的个体有效性。计算机1配备了一个i5-12400F处理器，32GB的RAM，和一个3060 GPU。表6显示了使用数据集C对不同模型的精度、查全率和f1评分值的定量比较，表明WCCN、CBAM和BiLSTM模块分别将故障诊断准确率提高了7.1%、4%和17.6%。有关更全面的比较，请参见表7。

5.4. 比较实验

5.4.1.5. 与其他网络的比较

在本节中，通过与其他7个WCCN-BiLSTM模型的比较来评估它的性能。图9(a)证明，与其他模型相比，所提出的模型在不同的配置上取得了更快的精度收敛速度。此外，与其他方法不同，它表现出显著的稳定性，在收敛后的精度波动最小。这表明该方法具有良好的收敛性和鲁棒性。下面的实验和分析集中于使用数据集C来说明每个模型的性能，它代表了常见的工作条件。

图9(b)图形化地显示了最先进的模型和所提出的模型的平均精度、查全率和F1分数。表8提供了对不同模型的时间消耗的全面比较分析，评估了它们的计算效率。为了衡量真实世界的性能，该测试集在两台具有不同规格的计算机上运行。计算机1配备i512400F处理器，32GBRAM和3060 GPU，而计算机2配备i9-13900KF处理器，48GBRAM和a4090 GPU。

为了减轻数据抽样顺序和初始权重设置对随机性的影响，这会导致不同实验结果的变化，进行多个实验并计算其平均值可以有效地减少这种变化。因此，在相同的参数设置下，我们进行了5次独立的实验，数据集C中测试集的故障诊断结果如图所示。9(c)。从图中可以看出，WCCN-BiLSTM模型的稳定性最高，平均精度最高，为98.9%。在




图8. 在整个模型训练过程中，值的变化。

表6
各模块烧蚀实验的定量比较结果。

索引	网络	BiLSTM	WKN-BiLSTM	WCCN	CNN-CBAM-BiLSTM	CNN-BiLSTM	CNN-CBAM
准确率	WCCN-BiLSTM CNN-CBAM-BiLSTM	WCCN t7%	CBAM t4%	BiLSTM t18%	WCCN t2%	CBAM t2%	BiLSTMt7%
召回率	WCCN-BiLSTM CNN-CBAM-BiLSTM	WCCN t7%	CBAM t4%	BiLSTMt18%	WCCN t2%	CBAM t2%	BiLSTMt8%
F1分数	WCCN-BiLSTM CNN-CBAM-BiLSTM	WCCN t7%	CBAM t4%	BiLSTMt18%	WCCN t2%	CBAM t2%	BiLSTMt8%
精度	WCCN-BiLSTM CNN-CBAM-BiLSTM	WCCN t7.1%	CBAM t4%	BiLSTMt17.6%	WCCN t1.4%	CBAM t2.2%	BiLSTMt7.7%

表7
对数据集C进行了烧蚀实验的定量评价结果。

网络	结构	输入	输出	准确率	召回率	F1分数	精度
WCCN-BiLSTM	CWConv（过滤器¼32，内核大小¼64，步幅¼1） Conv（过滤器¼28，内核大小¼33，步幅¼12）CBAM（）池化（池大小¼2，步幅¼2） BiLSTM（单位¼32） 稠密	(2048, 1) (2048, 32) (171, 28) (85, 28) (171, 28) (85, 28) (85, 72)	(2048, 32) (171, 28) (171, 28) (85, 28) (85, 28) (6120, 16)	0.99	0.99	0.99	0.988
BiLSTM	池（池大小=2，步幅= 2） BiLSTM（单位= 32） 稠密	(2048, 1) (1024, 1) (1024, 72)	(1024, 1) (1024, 72) (73, 728, 16)	0.92	0.92	0.92	0.917
WKN-BiLSTM	CWConv（过滤器= 32，内核大小= 64，步幅= 1） Conv（过滤器= 28，内核大小= 33，步幅= 12） 池（池大小=2，步幅= 2） BiLSTM（单位= 32） 稠密	(2048, 1) (2048, 32) (171, 28) (85, 28) (85, 72)	(2048, 32) (171, 28) (85, 28) (85, 28) (6120, 16)	0.95	0.95	0.95	0.948
WCCN	CWConv（过滤器= 32，内核大小= 64，步幅= 1） Conv（过滤器= 28，内核大小= 33，步幅= 12）CBAM（）池化（池大小=2，步幅= 2） 稠密	(2048, 1) (2048, 32) (171, 28) (171, 28) (85, 28)	(2048, 32) (171, 28) (171, 28) (85, 28) (2380, 16)	0.81	0.81	0.81	0.812
CNN-CBAM-BiLSTM	Conv（过滤器= 32，内核大小= 64，步幅= 1） Conv（过滤器= 28，内核大小= 33，步幅= 12） CBAM（） 池（池大小=2，步幅= 2） BiLSTM（单位= 32） 稠密	(2048, 1) (2048, 32) (171, 28) (171, 28) (85, 28) (85, 72)	(2048, 32) (171, 28) (171, 28) (85, 28) (85, 28) (6120, 16)	0.97	0.97	0.97	0.974
CNN-BiLSTM	Conv（过滤器= 32，内核大小= 64，步幅= 1） Conv（过滤器= 28，内核大小= 33，步幅= 12） 池（池大小=2，步幅= 2） BiLSTM（单位= 32） 稠密	(2048, 1) (2048, 32) (171, 28)	(2048, 32) (171, 28) (85, 28) (85, 28) (6120, 16)	0.97	0.97	0.97	0.966

	(85, 28)				
	(85, 72)				
CNN-CBAM	Conv（过滤器= 32，内核大小= 64，步幅= 1） Conv（过滤器= 28，内核大小= 33，步幅= 12） CBAM () 池（池大小=2，步幅= 2） 稠密	(2048, 1) (2048, 32) (171, 28) (171, 28) (85, 28)	(2048, 32) (171, 28) (171, 28) (85, 28) (2380, 16)	0.92 	0.91
				0.91	0.911

图10. 这个图突出了每个标签类的分类精度，特别关注那些低于95%的精度。结果表明，其他型号中的多个标签不符合95%的精度标记。然而，所提出的方法只有一个标签，准确率为94%，略低于95%。这些结果强调了WCCN-BiLSTM模型与其他方法相比具有优越的分类能力。

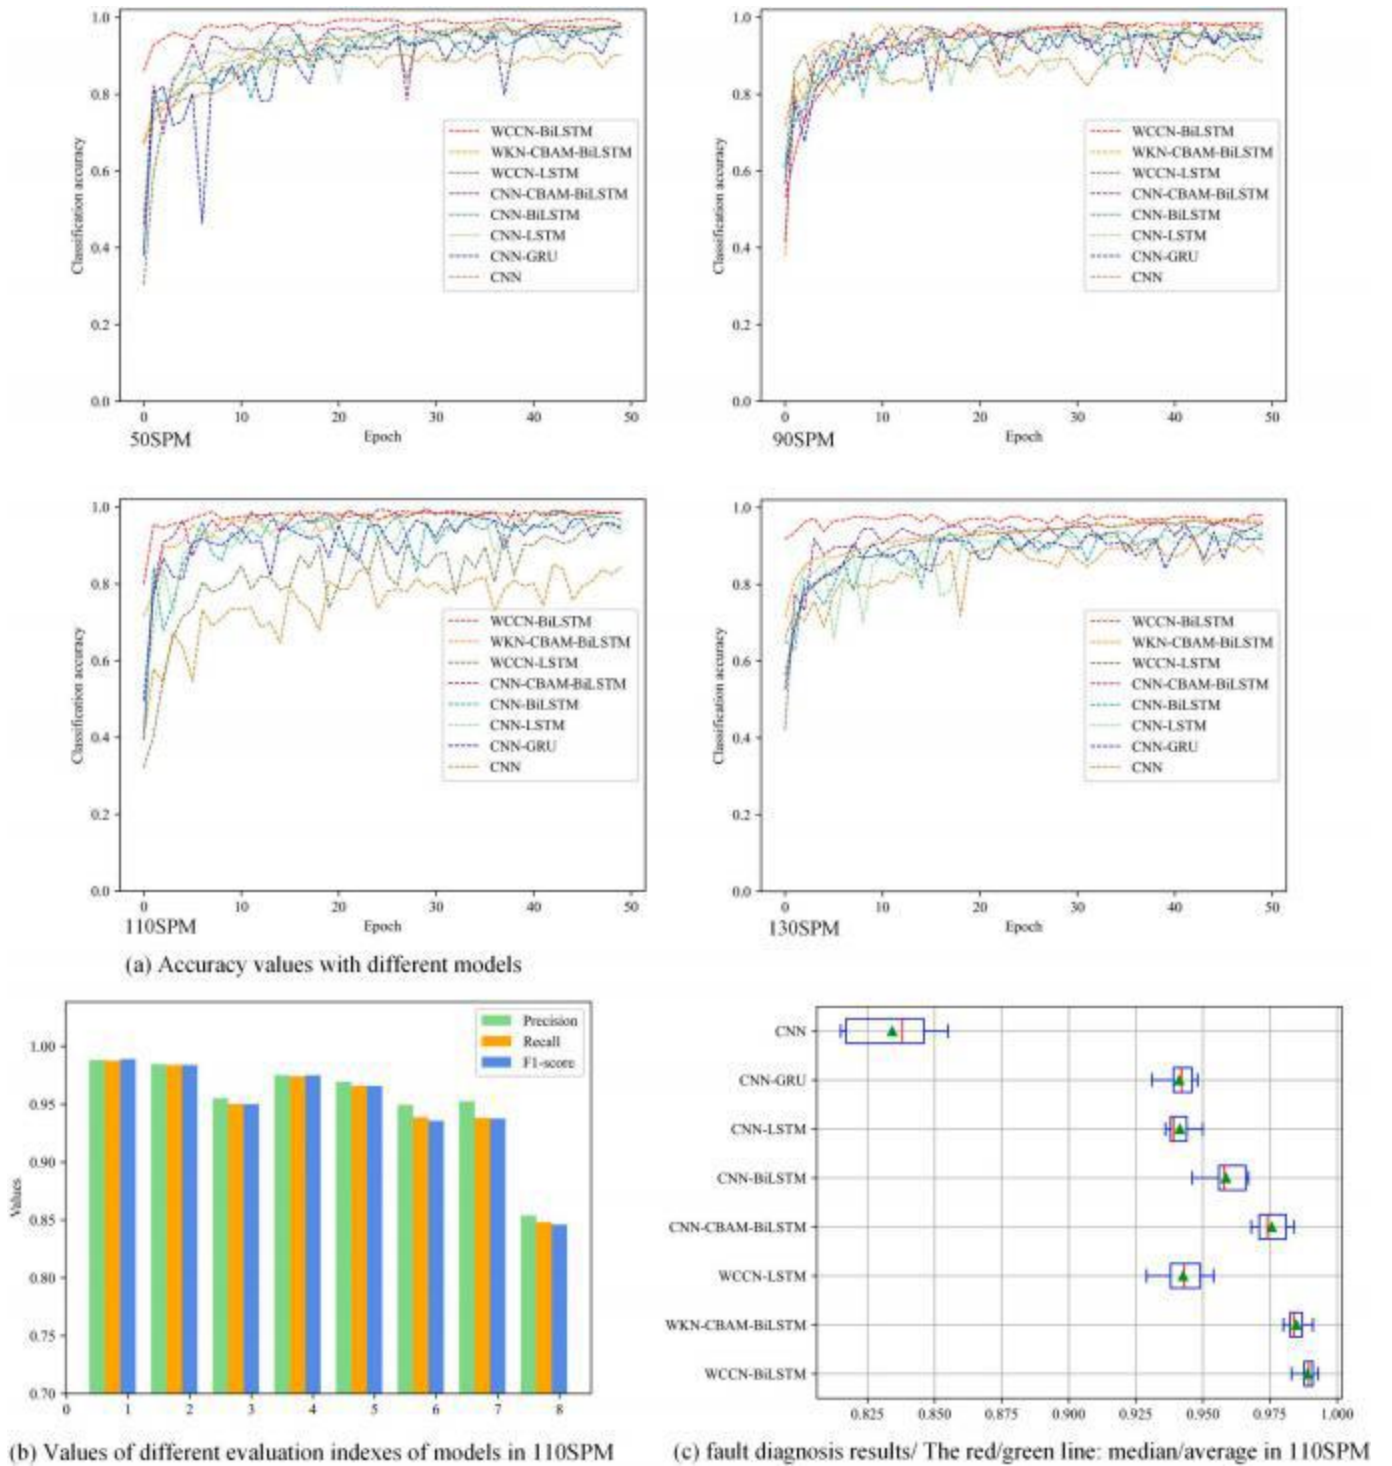


图9. 各种绩效指标 比较实验中的模型。

一种可视化技术,即t-SNE算法,引入了从数据点之间的高维欧氏距离到它们的相似度的条件概率[57]的转移。在将高维数据映射到低维数据的同时,保持了原始数据的相对相似性。为了评估该方法的特征提取能力,我们使用了t-SNE降维技术,如图所示。11。这个图显示了不同模型对不同标记的数据的不同分类能力。这个可视化清楚地展示了一些模型,比如CNN,在区分标签方面的能力较低,

导致不同标签的聚集。相比之下,该方法在T-SNE可视化方面明显更加熟练,实现了相同标签的清晰聚类,减少了不同标签之间的重叠,从而显示了其在钻泵故障诊断方面的有效性。图11还发现,WCCN-BiLSTM模型在对标签4对应的数据进行分类方面存在一定的局限性,与标签0和标签7有重叠,而其他模型也难以有效区分。尽管如此,WCCN-BiLSTM模型通常能有效地分类和识别不同的标签,而不是7个比较模型显示出不同程度的重叠。

表8

并对不同模型的定量评价结果进行了比较。

网络	准确率	召回率	F1分数	时间1	时间2
WCCN-BiLSTM	0.9881	0.9875	0.9888	5.98 s	4.68 s
WKN-CBAM-BiLSTM	0.9844	0.9838	0.9838	5 s.76	4 s.58
WCCN-LSTM	0.9550	0.9500	0.9500	5 s.05	3 s.92
CNN-CBAM-BiLSTM	0.9750	0.9740	0.9750	5 s.89	4 s.78
CNN-BiLSTM	0.9694	0.9656	0.9656	5 s.36	4 s.06
CNN-LSTM	0.9494	0.9388	0.9356	4 s.63	3 s.17
克恩格鲁	0.9525	0.9381	0.9375	4 s.43	3 s.01
中心体	0.8538	0.8480	0.8460	3 s.85	2 s.34

总体上所述, 该方法在特征空间上实现了更密集的聚类, 从而提高了钻井泵
的故障识别精度。

4.2.5. 其他去噪方法的比较

为了综合评价WCCN-BiLSTM模型的降噪效果, 设计了一个去噪比较实验。
最初, 对原始信号采用不同的降噪技术进行单独处理。随后, 将每种方法的
去噪信号输入CNNBiLSTM模型, 生成各自的输出。然后, 将这些输出结果与
WCCN-BiLSTM模型对原始信号的处理结果进行了比较。通过比较和分析不同
降噪方法下的故障诊断效果, 可以更清晰地判断其降噪效果, 从而对WCCN-
BiLSTM模型的降噪性能进行更全面的评价。表9描述了不同方法之间比较的
细节。结果还表明, 与其他降噪技术相比, 该方法具有良好的性能, 在任何
指标上都没有滞后。此外, 它

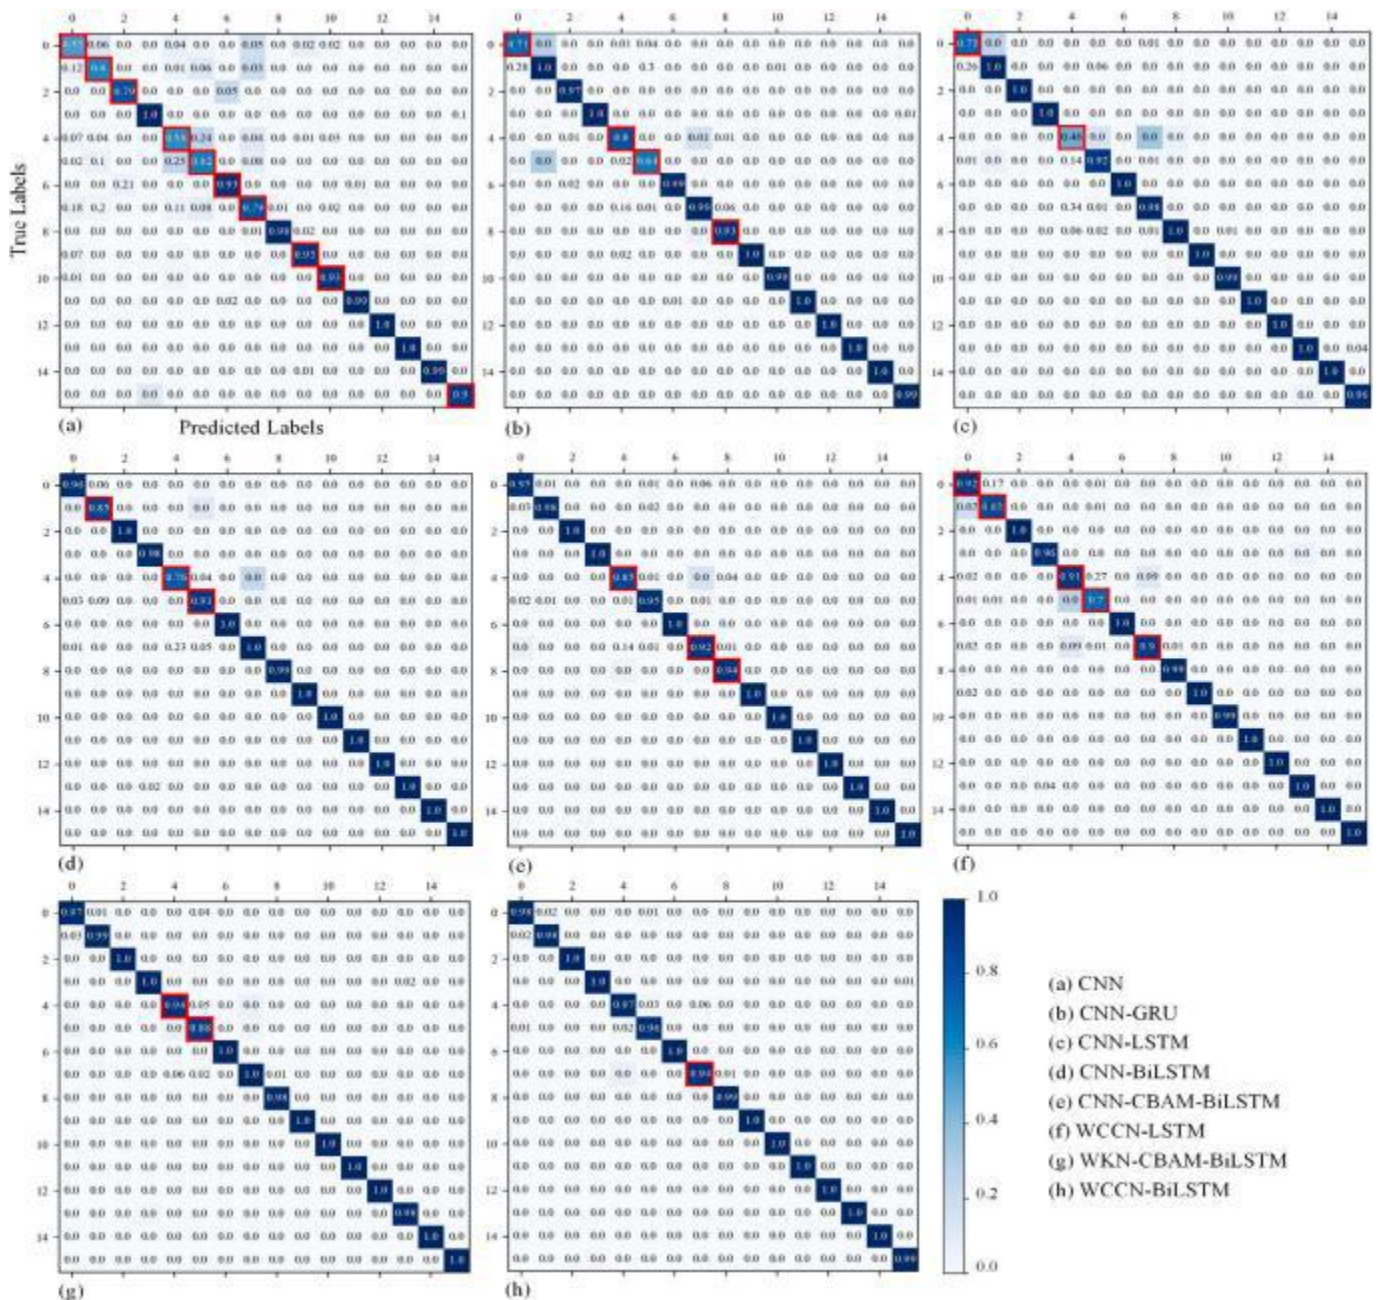


图10. 模型的混淆矩阵。

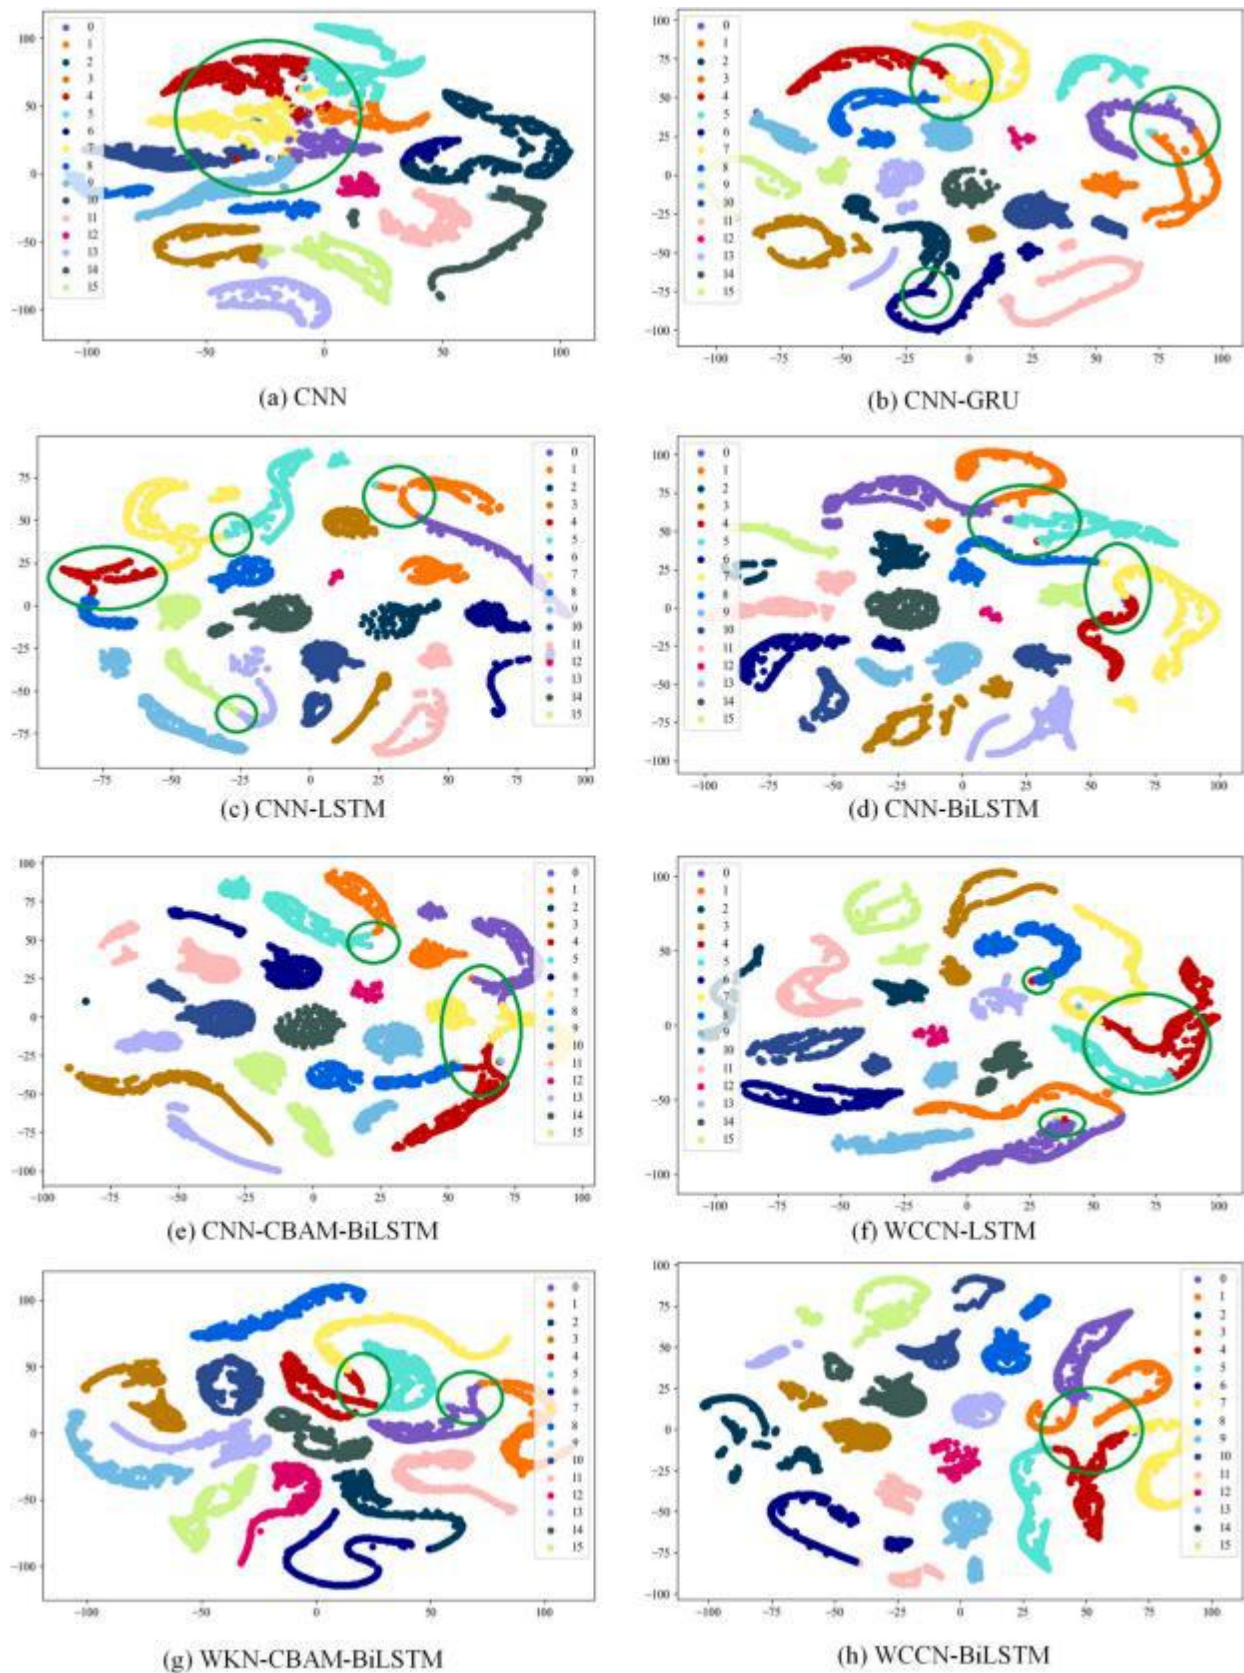


图11. 故障识别的比较。

表9

各种降噪技术的比较。

方法	精度	准确率	召回率	F1-得分	时间1	时间2
WCCN-BiLSTM	0.9888	0.9892	0.9888	0.9888	5.98 s	4.68 s
FFT-CNN-BiLSTM	0.9849	0.9852	0.9849	0.9849	9 s.45	7 s.45
Emd-cnn-BiLSTM	0.9888	0.9891	0.9888	0.9888	148.7 s	51.36 s
重量cnn-BiLSTM	0.9879	0.9882	0.9879	0.9878	9 s.25	6 s.07
CNN-BiLSTM	0.9656	0.9694	0.9656	0.9656	5 s.25	3 s.86

很明显，不采用降噪技术对钻泵的信号进行直接故障诊断效果较差。这些结果强调了该方法在信号降噪方面的有效性，对钻泵泵的故障诊断具有积极意义。

鉴于钻井泵现场的运行条件，信号预处理可以延长故障诊断时间，导致延误和可能发生的严重事故。因此，本小节不仅评估了每种降噪方法的准确性和其他指标，而且还对这些方法在两种不同计算机上的耗时性能进行了比较分析。1. 所使用的计算机与第5.3节中描述的计算机相同。具体地说，表9记录了每种方法处理测试集数据从读取到完成识别所需的平均时间，为这些方法的有效性提供了有价值的见解。从图中可以看出，在应用降噪技术后，不同方法在测试集上的运行时间会不同程度地增加。特别是，与不降噪相比，计算机1和2在计算机上花费的时间分别增加了13倍和28倍。时间支出的大幅增加显著提高了钻井泵故障诊断的总时间成本。与其他降噪技术相比，WCCN-BiLSTM内置的降噪方法对信号处理消耗时间的影响最小，在整个比较过程中显示出一致的效率。该方法能有效、准确地识别钻泵故障，提供工程价值。

5.5. 该模型的领域自适应能力

为了评价该方法的泛化能力，建立了一个跨不同数据集的领域自适应实验。

该微调方法有助于使最初在一个特定条件下训练的模型适应各种其他条件[58]。图12表明，在训练后，所提出的WCCN-BiLSTM方法的主干被冻结，只有输出层保持可调。随后，将训练后的网络部署到目标域的训练集上进行一次迭代。如前所述，在目标域中的训练只修改输出层，保持所提方法的主干不变。完成后，使用目标域的测试集对网络进行测试，以评估其自适应能力。

在领域自适应实验中，选择单一数据集作为训练模型的源域，而来自不同工作条件的数据集作为目标域来评估模型的自适应效果。与比较实验一样，领域自适应实验也在两台不同的计算机上展开。在这个过程中，我们细致地关注记录模型训练时间，以及自适应训练和测试阶段所花费的时间。表10给出了实验的具体结果，其中该模型最初使用源域数据进行训练，并进行了5次自适应试验。然后有系统地计算并记录这些实验的平均值。从表10中可以明显看出，与模型训练相比，自适应训练和测试显著减少了时间消耗。此外，获得了优越的结果，准确率始终超过95%，表明该方法具有鲁棒泛化性。

6. 结论

本文研究提出了一种用于钻泵故障诊断的智能故障诊断方法WCCNBilSTM。该方法为钻泵故障诊断提供了一种有效的策略。采用随机森林模型，识别出最准确地描述钻泵故障的信号。WCCN网络与BiLSTM相结合，提高了时间序列数据的降噪和特征提取能力，从而提高了诊断精度。该模型在快速处理噪声数据进行特征提取、改进特征和进行序列计算方面特别有效，为其优越的诊断性能奠定了坚实的基础。领域自适应实验取得了令人印象深刻的结果，以每个工作条件的数据集作为源域，在不改变其核心权重的情况下对模型进行微调，在目标领域的精度超过95%，证明了其具有较强的泛化能力。然而，仅依赖于单一的源机器可能无法产生足够的知识来进行关于目标机器的诊断决策。因此，未来

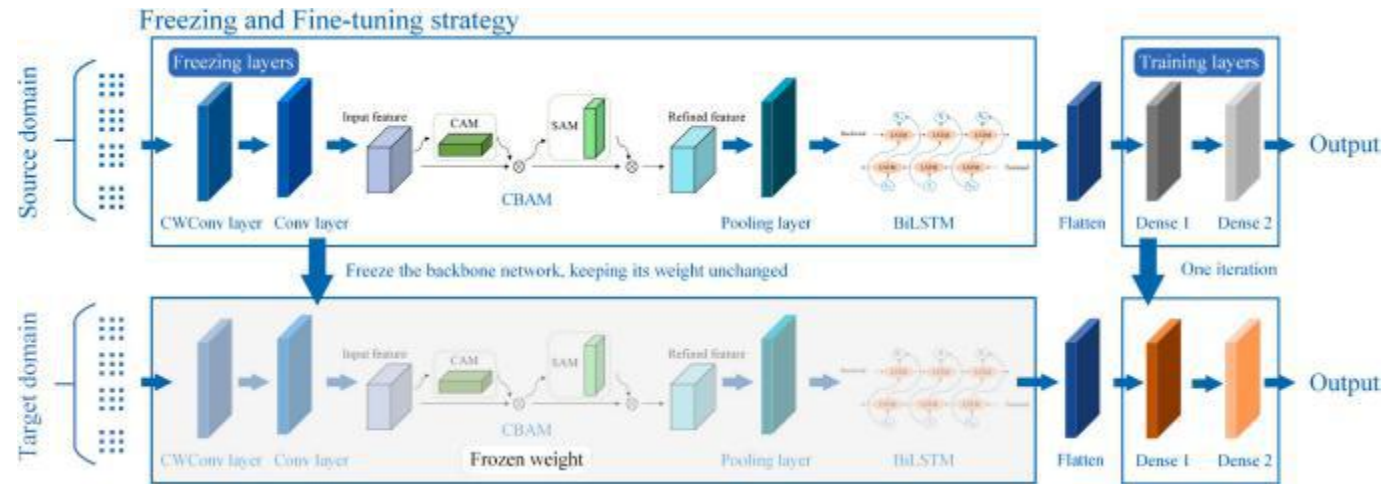


图12. 基于模型的WCCN-BiLSTM的迁移学习。

表10
该方法在领域自适应实验中的性能。

领域自适应	工作条件	精度	预测	召回率	F1痛	时间1	时间2
源域1	110 SPM	0.9913	0.9915	0.9913	0.9912	625.14 s	399.46 s
	50 SPM	0.9753	0.9777	0.9753	0.9755	14.93 s	11.37 s
目标域1	90 SPM	0.9856	0.9860	0.9856	0.9856	14.78 s	11.53 s
	130 SPM	0.9696	0.9701	0.9696	0.9695	15.02 s	11.76 s
源域2	50 SPM	0.9928	0.9928	0.9927	0.9927	619.48 s	406.36 s
	90 SPM	0.9776	0.9790	0.9776	0.9777	15.12 s	11.77 s
目标域2	110 SPM	0.9741	0.9752	0.9741	0.9741	15.03 s	11.71
	130 SPM	0.9594	0.9624	0.9594	0.9600	14.85 s	s 11.60 s
源域3	90 SPM	0.9922	0.9923	0.9922	0.9922	637.12 s	394.81 s
	50 SPM	0.9731	0.9746	0.9731	0.9730	14.97 s	11.58 s
目标域3	110 SPM	0.9804	0.9811	0.9804	0.9804	14.60s	11.39 s
	130 SPM	0.9578	0.9589	0.9578	0.9577	15.40s	11.71 s
源域4	130 SPM	0.9928	0.9929	0.9928	0.9928	624.56 s	398.56 s
	50 SPM	0.9811	0.9814	0.9811	0.9811	14.61 s	11.92 s
目标域4	90 SPM	0.9774	0.9776	0.9774	0.9774	15.20s	11.77 s
	110 SPM	0.9786	0.9791	0.9786	0.9787	14.70s	11.56 s

研究将探索开发一个多源诊断知识融合模块，以识别在目标领域内可能不明显的故障。此外，一个重要的未来方向是有效地将所提出的方法与工程实践相结合。

作者协议

该论文尚未作为一部分或整体发表，所有作者均同意提交并发表在《应用能源杂志》上。

信誉良好的作者贡献声明

郭俊宇：方法论，形式分析，概念化。杨玉莱：正式的分析、调查、方法论、写作、审查和编辑。李：原稿、监督、方法、调查、形式分析、概念化。王江：撰写-初稿、可视化、验证、调查、概念化。唐毅民：写作-初稿、可视化、验证、调查、概念化。戴维山：写作-原稿、可视化、验证、调查、概念化。黄邦奎：验证、数据管理。

相互竞争的利益的声明

没有利益冲突。

数据可用性

数据将根据要求提供。

确认信息

本研究由四川省自然科学基金资助项目 (No. 2023NSFSC0854)，教育部（西南石油大学）石油天然气设备重点实验室、宏华集团有限公司联合基金。（格兰特No. 06EHH202005），国家留学基金委（CSC）奖学金(资助No. 202108515059)。

参考文献

[1] Caldern AJ, Pekney NJ. 优化提高采收率作业非常规水库。Appl 能源2020；258：114072。
[2] Lobo DM, Ritto TG, 城堡酒店。一种新的随机过程钻岩相互作用中的岩石强度，用于钻柱振动分析。Mech 系统信号Pr2020；141：106451。
[3] Liu Z, 苏亚雷斯C. 系泊系统系绳材料的数值研究重力笼。海洋英语2024；298：117135。

[4]张Z, 赖十, 吴美, 陈林, 卢C, 杜S. 基于特征的故障诊断钻井过程中损失和启动的时间序列数据的聚类。J 过程控制2021；102：24-33。
[5]韩Y, 刘J, 刘P, 耿Z. 一个智能移动窗口的稀疏原则基于组件分析的基于案例的故障诊断推理：钻井过程的案例。Isa T 2022;128:242 - 54。
[6] Ye H, 李伟, 林世, 葛勇, 吕Q. 一种基于故障检测方法选择的框架海洋学多层绞车纤维绳的布置。测量：国际测量联合会杂志，2024年；226：114168。
[7]理发师, 克雷斯拉, [7], [7]. GMM的一个案例研究(图形对采矿行业的维护管理进行分析)。Reliab Eng Syst Saf 2014;121:113 - 20。
[8]BejgerA, [8]T. 利用声发射弹性波来诊断高钻井平台上使用的压力泥浆泵。能量2020；13：1138。
[9]邓S, 裴J, 王Y, 刘B. 基于钻井泥浆泵故障诊断的研究论声发射与振动技术的融合。洞察力-无损检测和状态监测, 2017年; 59年: 415-23年。
[10]王S, 陈H. 一种新的进行权力分类的深度学习方式使用深度卷积神经网络的质量干扰。Appl 能源2019；235：1126-40。
[11]石M, 丁C, 王R, 宋Q, 沈C, 黄W, 等。深超图自动编码器嵌入：一种有效的智能旋转机械故障诊断方法。基于kno s l 的系统2023；260：110172。
[12] Chen Q, 魏赫, 拉希德·M, 蔡Z. 基于核极端学习机用于多类型和并行故障诊断的分层机器学习。测量2021；184：109923。
[13]李Z, 江W, 张S, 孙Y, 张S. 一种液压泵故障诊断方法基于改进的集成经验模态分解和小波核极值学习机方法。传感器-巴塞尔2021；21：2599。
[14]刘子, 方左, 江德, 曲R. 一种基于机器学习的故障诊断方法采用多相驱动系统的自适应二次采样。2022年电力；37：8767-72。
[15] Lan Y, 胡J, 黄J, 牛L, 曾X, 熊X, 等。滑块故障诊断基于极限学习机的轴向活塞泵的磨损问题。测量2018；124：378-85。
[16]高Y, 宫田市S, 明石市Y. 如何提高深度的应用潜力暖通空调故障诊断中的学习模型：基于剪枝和可解释的深度学习方法。Appl 能源2023；348：121591。
[17], 王, 彭Z, 冯. 变分非线性分量分解用于变速条件下行星变速箱的故障诊断。Mech 系统信号Pr2022；162：108016。
[18]王C, 辛C, 徐Z. 一种新的不平衡故障深度度量学习模型诊断和向开放集分类。基于know l 的系统2021；220：106925。
[19]赵B, 张十, 李赫, 杨Z. 基于滚动轴承的智能故障诊断对考虑数据不平衡和可变工作条件的归一化CNN进行了分析。基于kno s l 的系统2020；199：105971。
[20] Kumar A, 甘地党, 周Y, Kumar R, 项J. 增强的深度卷积神经网络 (CNN)，用于利用声学图像识别离心泵中的缺陷。Appl Acoust 2020;167:107399。
[21]唐, 朱勇, 袁S. 一种改进的卷积神经网络对液压活塞泵多信号故障诊断的适应性学习率。Adv Eng 通知2021；50：101406。
[22]李, 胡, 山D, 奥J, 黄B, 黄Z. 一个基于创新的CNN模型膨胀操作提高钻井泵液端故障诊断精度。Mech 系统信号Pr2023；187：109974。
[23]·唐·A, 赵·W. 钻井泵液端部故障诊断方法时频变换。过程2023；11：1996。
[24] 郭林, 李恩, 贾福, 雷义, 林J. 一种基于递归神经网络的健康指标用于保持轴承的使用寿命预测。Neurocomputing 2017;240: 98 - 109。
[25]王J, 冀Y, 王Z, 江D. 风电系统的多故障诊断方法基于递归神经网络的生成系统。的诉讼程序

- 机械工程师学会, 第一部分: 2019年电力与能源杂志; 233: 604-15。
- [26] Sepp H, 尤尔根S. 长期记忆。神经合成1997; 8: 1735-80。[27], 杜, 吕, 庞, 郭勇。一种基于改进的综合方法和LSTM深度学习神经网络对往复泵的故障诊断。Ieee访问2021; 9: 23301-10。
- [28] Chung J, 先生, Y. 门控复发性疾病的实证评价在序列建模上的神经网络。Arxiv 2014.arXiv预印本arXiv: 1412.3555。
- [29] 苗X, 李世, 朱勇, 安Z. 一种新的行星实时故障诊断方法变速箱使用可转移的隐藏层。IEEE传感器J2020; 20: 8403-12。
- [30] 韩L, 邓Y, 陈H, 魏G, 凯盛石J. 一个稳健的VRF故障诊断基于具有注意机制的集成BiLSTM的方法: 考虑不确定性和泛化。埃涅尔格. 建筑2022; 269: 112243。
- [31] 梁, 陈, 朱, 金, 杜Z. 建筑过程中的领域知识分解能源消耗和一个混合数据驱动模型的24小时提前预测。Appl能源2023; 344: 121244。
- [32], 纳德卡尼F. 基于半监督聚类故障诊断与预后的方法: 一个案例研究。Reliab Eng Syst Saf 2022; 222:108405。
- [33] 李晓, 李日, 曲义, 何德。利用集成的CNN和GRU进行齿轮点合故障诊断同时具有振动和声发射信号的网络。Appl Sci 2019;9:768。
- [34] 王志军, 东勇, 刘伟, 马志军。一种新型的冷却器故障诊断方法基于一维卷积神经网络和门控递归单元。传感器-巴塞尔2020; 20: 2458。
- [35] 廖G, 高W, 杨G, 郭M. 水电发电机组故障诊断使用小水电系统中的一维卷积神经网络和门控循环单元。IEEE传感器J2019; 19: 9352-63。
- [36] 张十, 华十, 朱杰, 马m. 液体火箭发动机的智能故障诊断具有多感觉数据的可解释的LSTM。传感器-巴塞尔2023; 23: 5636。
- [37] 你K, 邱, 顾Y. 基于混合神经网络的滚动轴承故障诊断与主成分分析。传感器-巴塞尔2022; 22: 8906。
- [38] 翔L, 王P, 杨十, 胡安, 苏H. 风力发电机组的故障检测基于使用CNN和LSTM进行SCADA数据分析。测量2021; 175: 109094。
- [39] 王J, 郭J, 王L, 杨Y, 王Z, 王R. 混合智能滚动结合WKN-BiLSTM和注意机制的轴承故障诊断方法。Meas科学技术2023; 34: 85106。
- [40] 黄杰, 莫杰, 张杰, 马十世。一种基于光纤振动信号的识别方法在CNN-CBAM-LSTM。Appl Sci 2022;12:8478。
- [41] Xu Z, 美美, 王X, 岳, 金, 杨, 等。风力涡轮机的故障诊断轴承使用多尺度卷积神经网络与双向长短期记忆和加权多数投票的多传感器。更新能源2022; 182: 615-26。
- [42] 杨杰, 张杰, 赵杰, 翟杰, 陈十。使用来解释网络知识轴承故障诊断的注意机制。Appl 软通信输出2020; 97: 106829。
- [43] 你K, 邱, 顾Y. 一种使用BiLSTM-SCN-的高效轻量级神经网络CBAM, 用于诊断滚动轴承故障。Meas科学技术2023; 34: 94001。
- [44] Glowacz A. 利用热图像对微型肿瘤患者进行通气诊断。专家咨询师Appl 2024;237:121435。
- [45] 彭, 王H, W, 李。RMA-CNN: 残余混合域注意CNN的轴承故障诊断及及时频域可解释性。《动力学、监测和诊断杂志》, 2023年; 2: 115-32。
- [46] 郭J, 王Z, 李H, 杨Y, 黄C, Yazdi M, 等。混合预后方案基于一种新的健康指标和非线性维纳工艺的滚动轴承。Reliab Eng Syst Saf 2024;245:110014。
- [47] 香L, 杨十, 胡阿, 苏H, 王P. 状态监测和异常检测基于级联双向深度学习网络。Appl能源2022; 305: 117925。
- [48] 王C, 刘杰, 佐E. 一种改进的故障诊断生成对抗网络在高速列车组件与不平衡和不均匀的监测数据。动力学、监测和诊断杂志2022; 84-92。
- [49] 李T, 赵Z, 孙C, 程林, 陈X, 严R, 等。Wavelnetnet: 一个用于工业智能诊断的可解释的深度神经网络。IEEE跨系统人Cybern系统2022; 52: 2302-12。
- [50] Woo S, Park J, Lee J, Kweon是。CBAM: 卷积块注意模块。2018年欧洲计算机视觉会议 (Eccv) 论文集; 3-19。
- [51] Glowacz A. 换向器电气故障的热成像故障诊断和感应电动机。应用Intell2023; 121: 105962。
- [52] 王W, 雷Y, 严T, 李N, 南迪A. 残差卷积长期短期内存网络用于机器的剩余使用寿命预测和不确定性量化。动力学、监测和诊断杂志, 2022年; 1: 2-08年。
- [53] 郭J, 杨Y, 李H, 戴L, 黄B. 一种用于智能的并行深度神经网络钻井泵的故障诊断。2024年; 133: 108071年。
- [54] Breiman L. 随机森林。马赫学习2001; 45: 5-32。
- [55] 唐•S, 朱勇, 袁•S. 液压泵智能故障识别自适应归一化CNN和同步压缩小波变换。Reliab Eng Syst Saf 2022;224:108560。
- [56] 唐•S, 朱勇, 袁•S. 一种用于故障诊断的自适应深度学习模型液压活塞泵使用压力信号。Eng失败肛门2022; 138: 106300。
- [57] Van der Maaten L, 何顿G. 使用t-SNE可视化数据。J马赫学习经验, 2008; 9。
- [58], 吕勇、袁瑞、王勇。基于微调迁移学习结合自注意和频谱归一化的DCGAN进行轴承故障诊断。测量2023; 210: 112421。