



内容列表可在科学直接获得

## 海洋工程

期刊主页: [www.elsevier.com/locate/oceaneng](http://www.elsevier.com/locate/oceaneng)

## 研究论文

## CNN-LSTM-AM: 一个海上风力涡轮机的功率预测模型

孙玉<sup>a</sup>周奇波<sup>b</sup>李孙<sup>b</sup>孙丽萍<sup>a</sup>、康继川<sup>a, \*</sup>、何丽<sup>c, d, \*\*</sup><sup>a</sup>哈尔滨工程大学造船工程学院, 黑龙江哈尔滨, 150001<sup>b</sup>中国海洋设计研究院, 上海, 200001, 中国<sup>c</sup>利物浦约翰摩尔大学工程学院, 利物浦, 拜伦街3号, L3 3AF, 英国<sup>d</sup>葡萄牙里斯本大学, 印度高等海洋科学研究所, 海洋技术和海洋工程中心 (CENTEC)

## ARTICLE INFO

关键词:  
海上风力涡轮机  
功率预测  
多传感器融合  
深度学习  
传感器灵敏度

## ABSTRACT

本研究介绍了一种功率预测模型, 即卷积神经网络 (CNN)-长短期记忆 (LSTM)-注意机制 (AM) 算法 (CNN-LSTM-AM), 旨在基于SCADA系统收集的数据来预测海上风力涡轮机的功率。该模型采用时间步长参数化方法进行海上风力涡轮机预测, 促进了训练数据集的自动划分, 并简化了训练过程。提出了一个CNN-LSTM-AM网络, 利用来自多个传感器的信号来预测海上风力涡轮机的功率。通过变量控制比较, 完成了传感器的灵敏度分析, 确定了最适合进行功率预测的传感器组。与现有的深度学习算法相比, 该模型在功率预测方面的最大提高为13.77%。结果表明, 变速箱高速轴的轮毂和尾部温度是海上风力发电预测的关键。总的来说, 本研究的结果有助于海上风力涡轮机的运行和维护以及海上风电场的管理。

## 1. 介绍

预计到2030年, 风能将产生世界发电量的五分之一, 预计到2050年将增加三分之二 (理事会GWE, 2023年)。与陆上风电相比, 海上风力具有一些优势, 包括减少环境影响 (Li等人, 2021a年)、适应性更强的风电场配置 (Kang等人, 2019年)、优越的风廓线 (锯和布罗韦尔, 2022年) 以及减少叶片尺寸限制 (Foley等人, 2012年)。

然而, 海上风电的扩张遇到了一些与环境、电网和市场因素相关的挑战。具体而言, (i) 风电的间歇性、波动性和不可预测性影响电网调度和运行 (Qian等, 2019); (ii) 电网资源有限的可调性影响电力消耗, 导致风力缩减 (McDonagh等, 2020; Bird等, 2016年); 2 (iii) 发电波动阻碍海上风力涡轮机 (OWT) 运营商制定可行的发电和维护计划以满足市场需求 (Li等, 2022a), 从而导致运营成本上升, 降低市场竞争力。

因此, 准确预测风力发电是至关重要的。预测精度仅提高10%, 风力发电能力就提高了约30% (阿克曼和斯德尔, 2000年)。为了降低运营成本和提高OWT的安全性, 精确的功率预测必须能够预测子孙后代并提前做出明智的决定 (Costa et al., 2008)。海上风电预测的各种方法包括物理、统计、智能和混合模型 (Hanifi等人, 2020年)。基于物理的模型, 如数值天气预报 (NWP) (Wang等人, 2019年; 多纳迪奥等人, 2021年) 和天气研究和预报 (WRF) (Qureshi等人, 2003)。然而, 基于统计的预测单变量时间序列的模型 (Jung和布罗德沃特, 2014; 拉扎和科斯拉维, 2015; 巴塞洛缪, 1971), 如自回归综合移动平均线 (ARIMA), 由于其计算时间成本低, 易于制定, 非常适合短期风力发电预测 (Yatiana等人, 2017; Jung和Kwon, 2013)。然而, 他们没有考虑到风力涡轮机的物理状况, 因此可能不能准确地反映长期情况

\*通讯作者。

\*\*通讯作者。

电子邮箱地址: 康日川@hrbeu.edu.cn (J. 康), 他。li@centec. 特克尼科。ulisboa.pt (H. 列支敦士登)

<https://doi.org/10.1016/j.oceaneng.2024.117598>

2023年11月11日收到; 2024年3月13日收到表格; 2024年3月19日接受

2024年3月23日在线提供

0029-8018/©2024爱思唯尔有限公司。保留所有权利。

设备的性能。

深度学习的出现引入了捕获非线性特征的新解决方案，被称为智能模型（Manero等人，2018年；Nezhad等人，2024年）。例如，Jyothi和Rao（2016）引入了一种自适应小波神经网络（AWNN），用于短期风力发电预测。Kisvari等人。（2021）提出了一个基于门控循环单元（GRU）和长短期记忆（LSTM）的模型来构建优化的预测模型。林等人。（Lin和Liu，2020）利用监控和数据采集（SCADA）数据开发了一个用于海上风电预测的深度学习模型。余等人。（2020）利用所提出的叠加图神经网络方法进行了特征提取和风能预测。针对操作数据中的异常、多模态和不确定性，Xin等人。（Xing和He，2023）将基于密度的噪声应用空间聚类纳入预测模型，从而提高了风力涡轮机功率预测的精度。

上面提到的功率预测模型通常是基于来自信号传感器的数据。然而，随着数据量的扩大，这些模型的预测性能受到了限制。因此，研究人员采用了混合模型来解决这个问题。例如，Neshat等人。（2021）采用了一种结合深度学习和进化方法的混合方法和四元数卷积神经网络（CNN）（Neshat et al., 2022），以提高风速预测的准确性。张等人。（2022）利用离散小波变换和季节自回归积分移动平均数，解决了功率时间序列预测问题的各个组成部分。海达里等人。（2021）提出了一种由经验模式分解和深度学习算法组成的混合预测模型。胡等人。（2021）提出了一种混合风力发电预报方法，该方法将修正后的数值天气预测和空间相关性集成到高斯过程中。哈尼菲等人。（2023）提出了一种基于小波包分解、优化的LSTM和CNN的组合模型来预测风力涡轮机的功率。

人们已经提出了许多利用气象数据（温度、风速、压力等）来预测风力涡轮机功率的方法，运行数据（电机转速、俯仰角、风力功率等。），或者两者都有。然而，风力涡轮机的气象传感器，如超声波风速计，已被证明会失效（根据LGS-海上数据集，每年超过15次），因此限制了功率预测模型的性能（Li和圭德斯·苏亚雷斯，2022；Li等，2021b；Sun等，2023）。因此，该部门正在寻找新的功率预测模型，不需要气象传感器来保护预测系统，并提供稳健的结果。同时，对传感器与风力涡轮机功率之间关系的理解是有限的。了解每个传感器对风力涡轮机的功率预测性能的贡献是至关重要的。

在此基础上，提出了一种无气象数据的风电预报多传感器融合模型。并对多传感器进行了灵敏度分析。本研究的新贡献如下。

- (i) 提出了一种CNN-LSTM-AM方法，通过集成来自多个组件的传感器数据来准确预测owt的功率。
- (ii) 对owt的功率预测的时间步长进行参数化，以随时间更新预测结果。
- (iii) 分析了传感器的灵敏度，以反映它们对功率预测的影响。

本文的其余部分组织如下：方法在第2和3节。研究结果、比较和讨论详见第4节。最后，结论见第5节。

## 2. 方法学

本研究基于CNN-LSTM-am算法构建了OWTs的功率预测模型，其中CNN从传感器数据中提取特征，LSTM对具有时间特征的信号进行处理，注意机制（AM）在时间序列中捕获关键信息。

### 2.1. 2卷积神经网络（CNN）

cnn由卷积层、激活层、池化层、全连接层和输出层组成（LeCun et al., 1998）。一个传统的卷积网络结构如图所示。1（Zare和Ayati，2021年）。

#### (1) 卷积层

卷积层从输入数据中提取信息。在卷积核内的特征提取被表示为

$$C_{fj}^n = \sigma \left( w_{fj}^n \otimes C_{fj}^{n-1} + b_{fj}^n \right) \quad (1)$$

其中 $C_{fj}^n$ 是第n个卷积层的第j个特征； $\sigma(\cdot)$ 为非线性激活函数； $\otimes$ 表示卷积计算； $w_{fj}^n$ 表示第n个卷积层的第j个权重矩阵； $C_{fj}^{n-1}$ 表示第(n-1)个卷积层的第j个输出值；和 $b_{fj}^n$ 是第n个卷积层的第j个偏差向量。

#### (2) 池层：

池化层从卷积层对输出进行采样。在本研究中，使用最大池化层来连接卷积层进行下采样，用

$$P_f^n = \max \left( C_{fj}^n \right), \quad (2)$$

其中 $P_f^n$ 是池化层的输出， $\max(\cdot)$ 是最大值C的下·采样函数 $\gamma^{n-1}$ 为卷积层的特征向量，s为池化大小。

#### (3) 全连接层

全连接层通过将前一层的所有神经元与当前层的所有神经元连接起来来实现特征组合和转换。

$$y_{特征} = \sigma \left( w_{f'} x + b_{f'} \right), \quad (3)$$

y在哪里 $_{特征}$ 表示特征向量， $w_{f'}$ 表示权重矩阵， $b_{f'}$ 是偏差向量，x是输入向量。 $\sigma(\cdot)$ 是非线性激活函数。

#### (4) 输出层

输出层传输该数据的内部计算结果

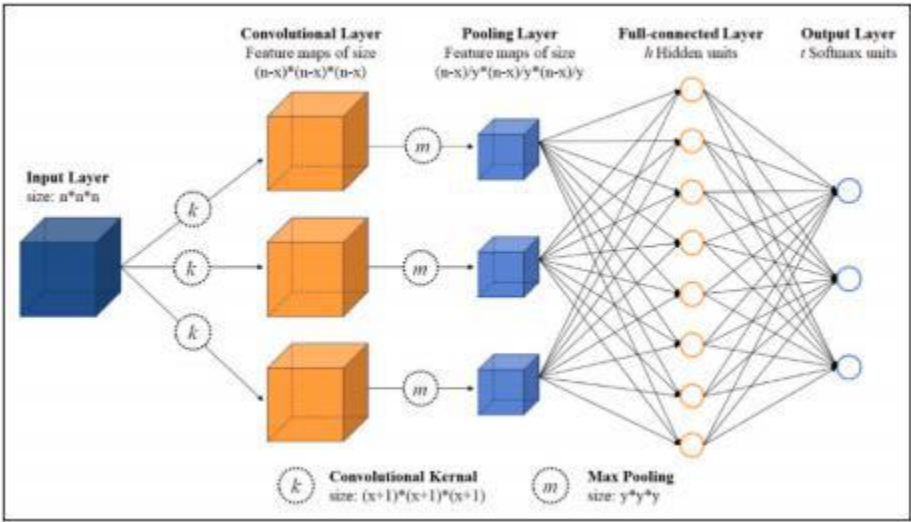


图1. 卷积神经网络（CNNs）示意图。

神经网络到外部环境。

$$(w, b)^* = \underset{(w, b)}{\operatorname{argmin}} \frac{1}{m} \sum_{i=1}^m L(y_{\text{真正的}}, y_{\text{估计的}}) \quad (4)$$

其中， $m$ 为标记数据集的数量， $L(\cdot)$ 表示损失函数， $y_{\text{真正的}}$ 和 $y_{\text{估计的}}$ 分别表示CNN的标签值和估计输出。 $\{w, b\}^*$ 为微调后的参数权重向量 $w$ 和偏差 $b$ ，它们是通过最小化损失函数 $L(\cdot)$ 得到的。

利用CNN对源数据获得空间特征，处理后的数据作为基于AM的LSTM的输入进行时间序列预测。

2.2长短期记忆（LSTM）

LSTM最初是由霍克雷特和施米德胡伯在1997年提出的（霍克雷特和雨尔根，1997年）。它从循环神经网络（RNN）结构发展而来，并发展出多种变化（Sun et al., 2022）。它在分类、处理和预测时间序列方面的优越性使得LSTM在处理长时间数据时优于替代rnn和其他时间序列学习方法（格雷夫斯和施米德胡伯，2005；Greff等人，2015）。神经网络（ANN）、RNN和LSTM架构示意图如图所示。2.

给定输入 $x = \{x_1, x_2, \dots, x_n\}$ 和LSTM的循环输入 $h$ ，在控制下对 $c$ 状态进行数值更新

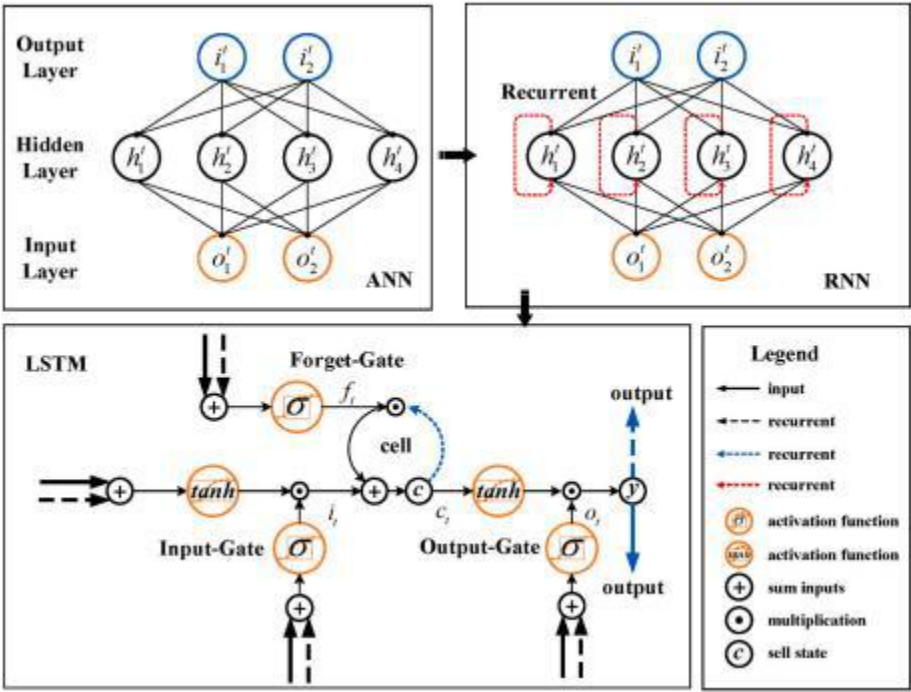


图2. 人工神经网络（ANN）、递归神经网络（RNN）和（长短期记忆）LSTM结构示意图。

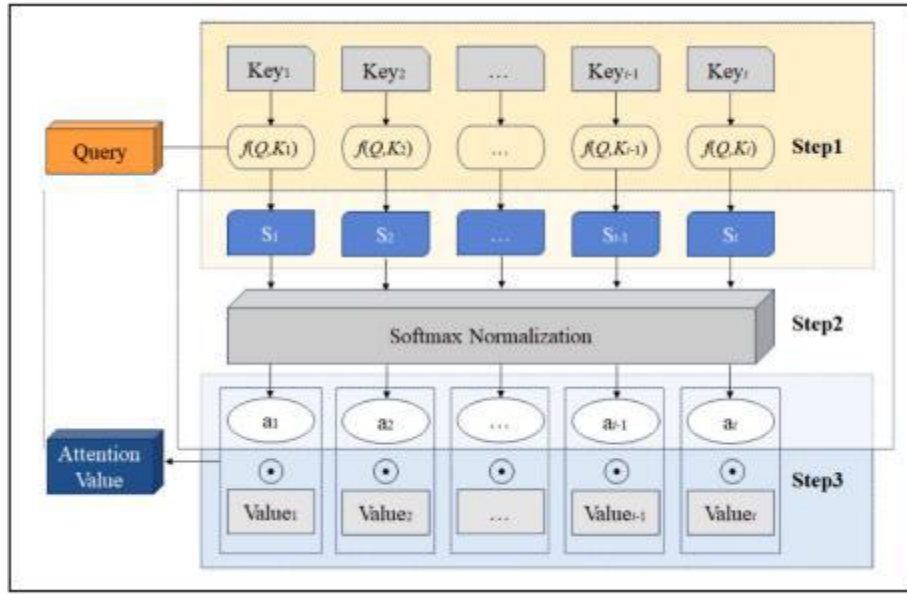


图3. 注意机制示意图 (AM)。

的大门。忘记门 $f_t$ 决定有多少细胞状态 $c_{t-1}$ 在之前的时刻仍处于细胞状态 $c_t$ 在当前时刻。输出值为：

$$f_t = \text{sigmoid}(W_f [h_{t-1}, x_t] + b_f), \quad (5)$$

其中s型是激活函数，可以在等式中描述

(6).  $W_f$ 是遗忘权重矩阵，和 $b_f$ 是遗忘的偏见。

$$\text{sigmoid}(z) = \frac{1}{1 + e^{-z}} \quad (6)$$

我在哪里 $t$ 是一个决定初始单元状态的数量输入门，以及 $\tilde{c}_t$ 对应于电流输入值 $x_t$ 被保存到单元状态 $c_t$ 在当前时刻。该门的输出值计算为

$$i_t = \text{sigmoid}(W_i [h_{t-1}, x_t] + b_i), \quad (7)$$

其中 $W_i$ 是输入的权重矩阵和 $b_i$ 是输入偏差。当前单元状态更新如下：

$$c_t = f_t * c_{t-1} + i_t * \tilde{c}_t, \quad (8)$$

在哪里 $o_t$ 表示控制单元状态的数量 $c$ 的输出门 $t$ 。输出门的值计算为

$$o_t = \text{sigmoid}(W_o [h_{t-1}, x_t] + b_o). \quad (9)$$

循环输入和 $y$ 的值为

$$y_t = o_t * \tanh(C_t), \quad (10)$$

其中 $\tanh$ 是激活函数，可以用等式来描述

(11).

$$\tanh(z) = (e^z - e^{-z}) / (e^z + e^{-z}) \quad (11)$$

### 3. 2注意机制 (AM)

AM可以描述为查询和一组密钥值对到输出的映射，其中查询、键、值和输出都是向量 (Mnih等人, 2014; Vaswani等人, 2017)。兼容性函数，以加权的形式计算，是分配给每个值的权重的输出 (Lu等人, 2021; Xiang等人, 2021)。如图所示。3、AM的计算过程一般分为三个步骤。

**步进 #1.** 假设信息由 {Key, Value} 的一些列组成，则查询 (输出特性) 和键 (输入特性) 之间的相似性或相关性计算为

$$s_t = f(Q, K_t) = \tanh(W_h h_t + b_h), \quad (12)$$

其中 $W_h$ 是AM的重量， $b_h$ 是AM和 $h$ 的偏差 $t$ 是输入向量。

**步进 #2.** 第一阶段的分数归一化，使用softmax函数转换注意力得分，可以描述为

$$a_t = \text{softmax}(s_t) = \frac{\exp(s_t)}{\sum \exp(s_t)}, \quad (13)$$

其中， $v$ 是注意值。

**步进 #3.** 通过计算权重来获得最终的注意

$$s = \sum_t a_t h_t. \quad (14)$$



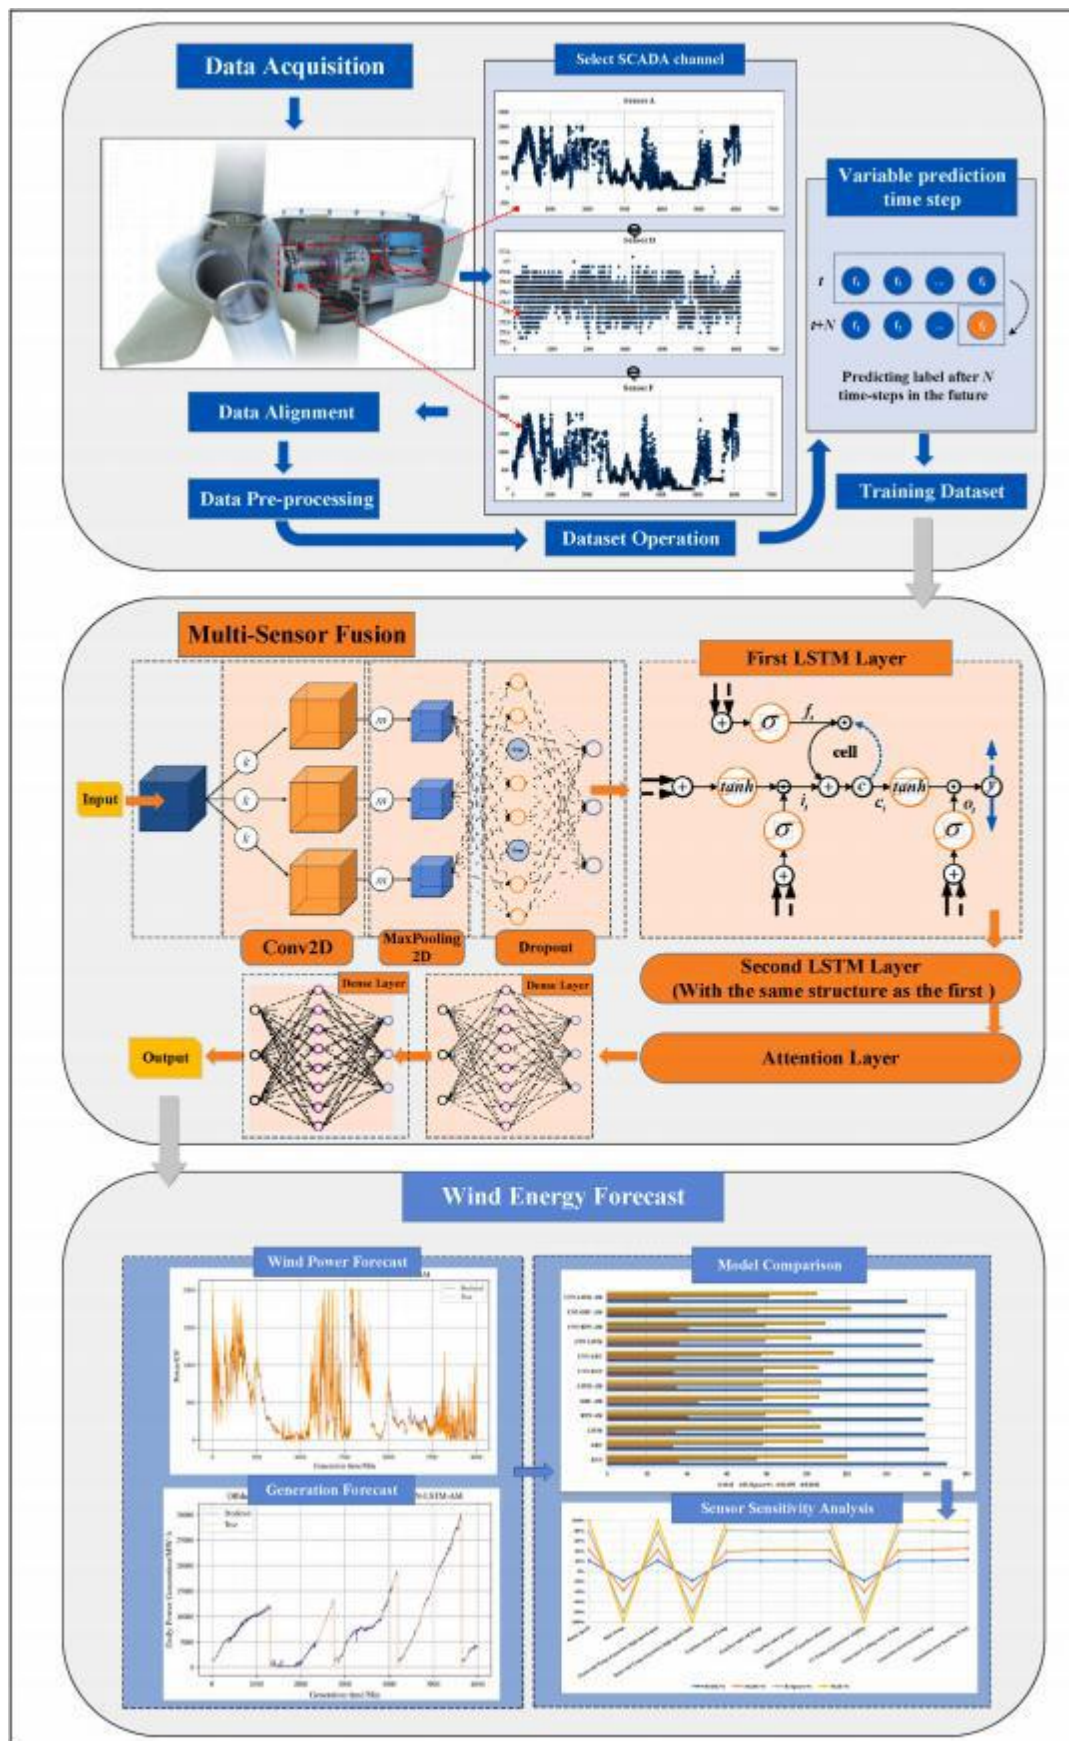


图4. owt功率预测的总体框架。

表1  
CNN-LSTM-AM算法。

算法CNN-LSTM-AM。	
1	输入：预测时间步长N，即训练集；
2	数据预处理：数据重组、数据规范化；
3	构建和初始化：CNN-LSTM-AM；对于epoch = 1, 2, ...,
4	epoch做：#通过CNN层训练CNN-LSTM-AM数据处理；LSTM
5	层数据处理；AM层数据处理；数据处理；获得CNN-LSTM-
6	AM的输出；计算损失和梯度计算损失函数，计算梯度；#
7	Adam算法优化参数；
8	最后部分
9	数据后处理：数据非规范化处理；
10	输出：以N分钟为单位的功率预测
11	
12	
13	
14	
15	
16	

表2  
CNN-LSTM-AM的训练配置参数。

参数	价值
迭代次数	50
批量大小	512
损失函数	均方误差
优化器	亚当

表3  
CNN-LSTM-AM的体系结构参数。

层	超参数
卷积层	过滤器= 32，内核大小=3，激活= ReLU
最大池层数	池大小=2
LSTM层1	10，返回序列= True
LSTM层2	20，返回序列=为真
注意事项	注意（10）
密度1	10，激活= ReLU
密度2	1

过滤器：卷积内核数；nerelen\_size：卷积内核的大小；激活：激活函数。

2. 4. 所提出的CNN-LSTM-AM模型

它的框架和所提出的功率预测模型如图所示。4.（一）数据采集。采用了SCADA通道，包括来自owt的12种传感器类型和来自陆上风力涡轮机的13种传感器类型。（ii）多传感器融合。利用CNN从多传感器数据中提取空间特征。LSTM的第一层和第二层负责提取时间特征。AM用于捕获长时间序列内的依赖关系。（iii）功率预测。采用训练后的CNN-LSTM-AM模型，根据均方误差（RMSE）、平均绝对百分比误差（MAPE）、平均绝对误差等指标，预测OWTs的功率（MAE）和r平方。CNN-LSTM-AM算法见表1。

用于训练CNN-LSTM-AM网络的参数如表2所示。采用均方误差作为损失函数，和

表4  
风力涡轮机的传感器（陆上和海上）。

离岸的		岸上的	
组件传感器组件传感器			
转子	转子转速	主要的	前轴承温度
轮毂	集线器温度	轴承轴制动	后轴承温度
齿轮箱	HSS的前端温度	器发电机	液压压力
	HSS的尾部温度		发电机转速
	油池温度		GW的最大温度
	进口油温度		GWU1温度
	进口压力		发电机冷却水温度
	出压力		发电机前轴承温度
	共和党		发电机后轴承
	GWU1温度		临时雇员
生成器	冷却水		发电机滑动环腔室温度
	临时雇员		发电机扭矩
	前轴承		变频器内部温度：变频器内
	临时雇员		部直流电压
	后轴承温度		

HSS：高速轴；GW：发电机绕组；GOP：变速箱油泵；温度：温度。

亚当作为一个优化器来优化网络的权重。该模型的架构参数如表3所示。为了评估所提出的模型的性能，有几个指标，包括RMSE（Eq.（15）），MAPE（Eq.（16）），MAE（Eq.（17））和Rsquare（R<sup>2</sup>，Eq.（18））计算。具体而言：

知道真正的价值y<sub>i</sub>和n个样本中的预测值y<sub>i</sub>，上述准则可计算为

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \tag{15}$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \tag{16}$$

$$MAE(y_i) = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \tag{17}$$
$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

3. 结果、比较和讨论

本节介绍了对CNN-LSTM-AM模型的评估。分析了用于风能预测的传感器的灵敏度。通过与11种深度学习方法的比较，讨论了该预测模型的性能。

3. 1. 3数据源

在本研究中，有来自转子、轮毂、主轴承、轴制动器、变速箱、发电机、变频器7个部件的SCADA数据

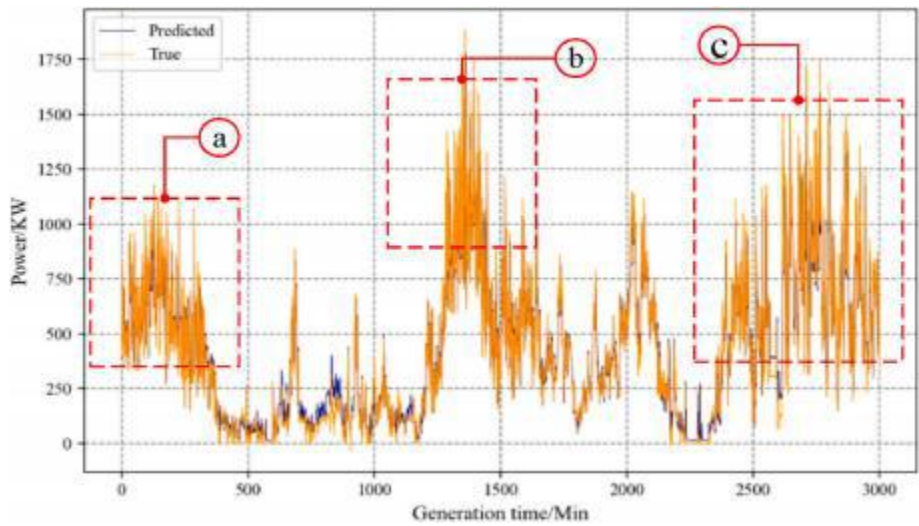


图5. WT1的功率预测。




图6. WT2的功率预测。

使用。这些组件构成了驱动链的核心，负责将风能转化为动能（Li et al.，2020, 2022b, 2022c）。本研究中使用的数据来自LGS-海上数据集，主要包括两个部分，如表4所示：（i）来自8个配备12个传感器的owt的SCADA数据，以及（ii）来自两个配备13个传感器的陆上风力涡轮机的SCADA数据。

2.3结果

为了证明该方法的性能，我们实现了两个案例：（i）案例1：具有13个传感器的陆地风力涡轮机的功率预测；（ii）案例2：12人的功率预测

传感器图。5和6给出了基于该方法的陆上风力涡轮机1（WT1）和2（WT2）的功率预测结果。在图5中，提出了对3000个时间步长的预测。值得注意的是，在500-1000的时间步长范围内，预测的功率超过了真实值，而在2300-2400的范围内相似，但仍保持在500 kW以下。这种差异是由于低风速、发电机故障和齿轮箱故障等因素造成的。另外，如图所示，a、b、c区域的真实功率超过了预测值。值得注意的是，受气象条件的影响，风力在8-16小时内上升到峰值，然后迅速下降。具体来说，风速的变化直接导致功率波动，因为风速是决定风力的最关键因素。风向的频繁变化影响转子扫掠区域



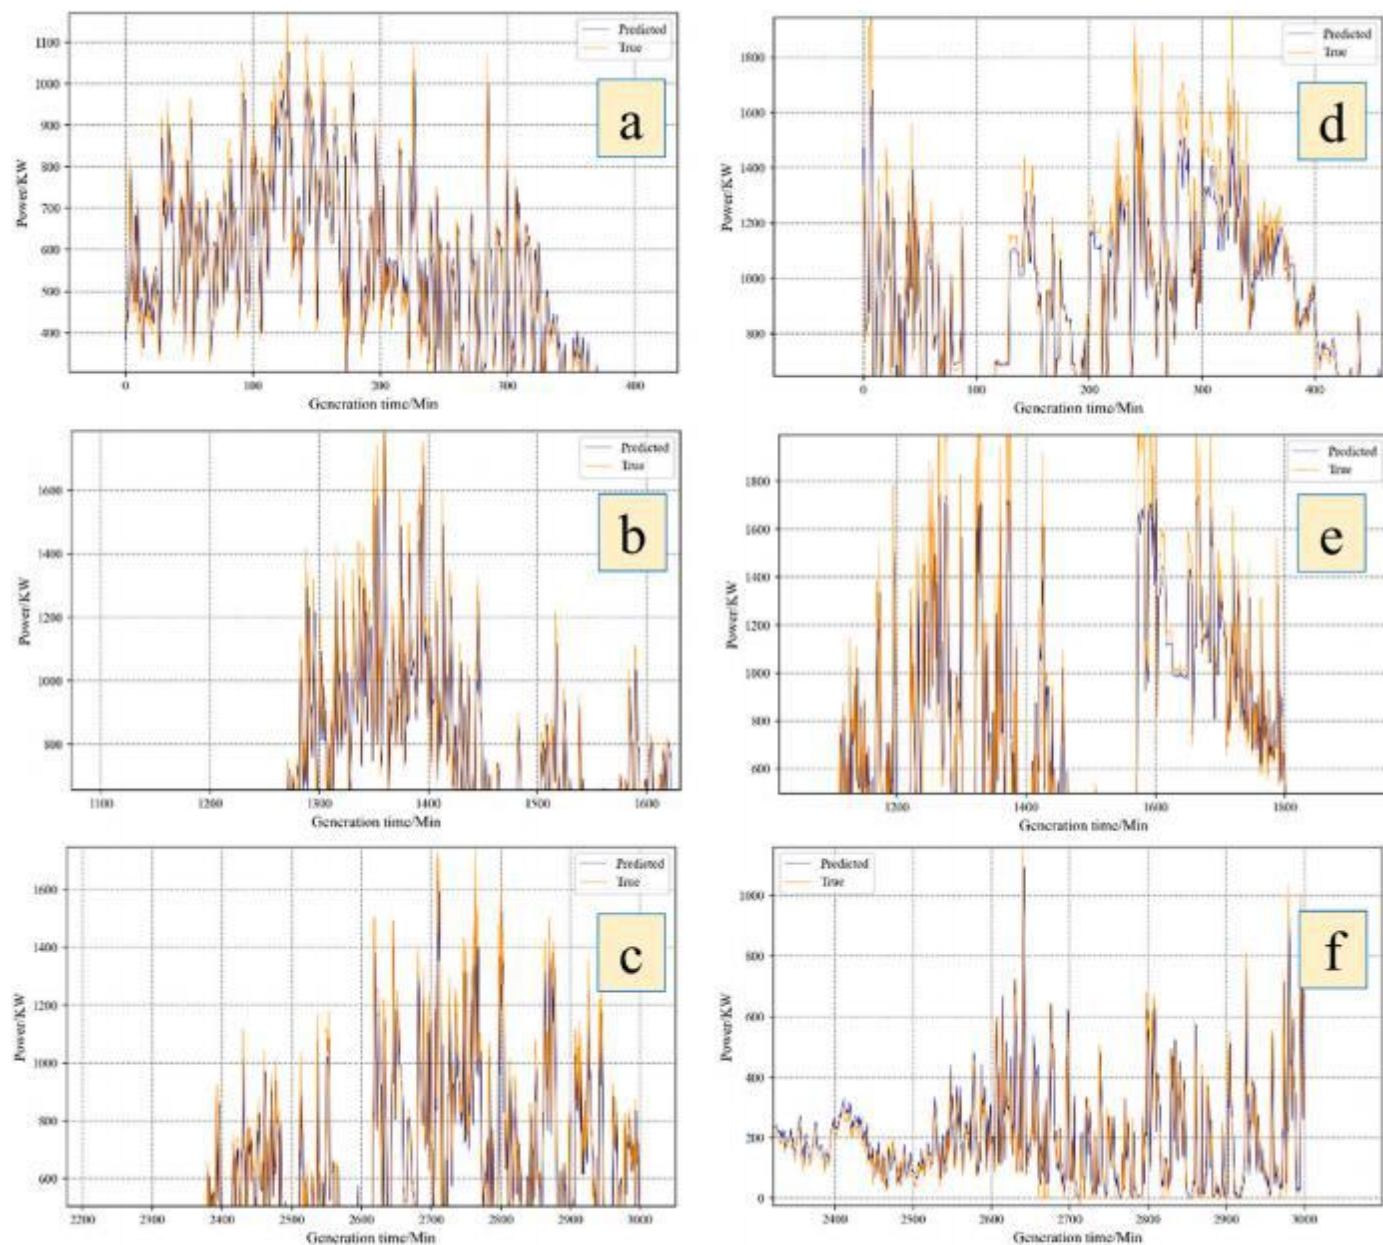


图7. 陆上风力机/WT1: (a)–(c); WT2: (d)–(f)。

风, 从而影响发电。

WT1功率预测的RMSE、MAE和 $r$ 平方值分别为150.24、0.81和105.12。分别与WT2的值进行比较, 分别为149.56、30.24和101.36。另一个值得注意的观察结果是, WT2的峰值功率在多个时间步长内达到其额定功率。然而, 与WT1相似, WT2的功率曲线表现出大约500个时间步长的周期波动。

图8显示了海上风力涡轮机OWT1和OWT 8在1、2、5、10和60 min时间步长上的多个时间步长的功率预测。不同预测时间步长的评价指标列于

表5。在海上风力涡轮机上使用时间步长参数化预测的数据集上实现了多个时间步长预测。可以看出, 前四种时间步长的精度相对较高, 但在预测60 min后, 精度误差开始显著下降, 如图所示。9和10。值得注意的是,  $r$ -平方大于0.5的模型被认为具有良好的性能。

### 3.3. 比较

为了验证CNN-LSTM-AM算法的准确性, 11深



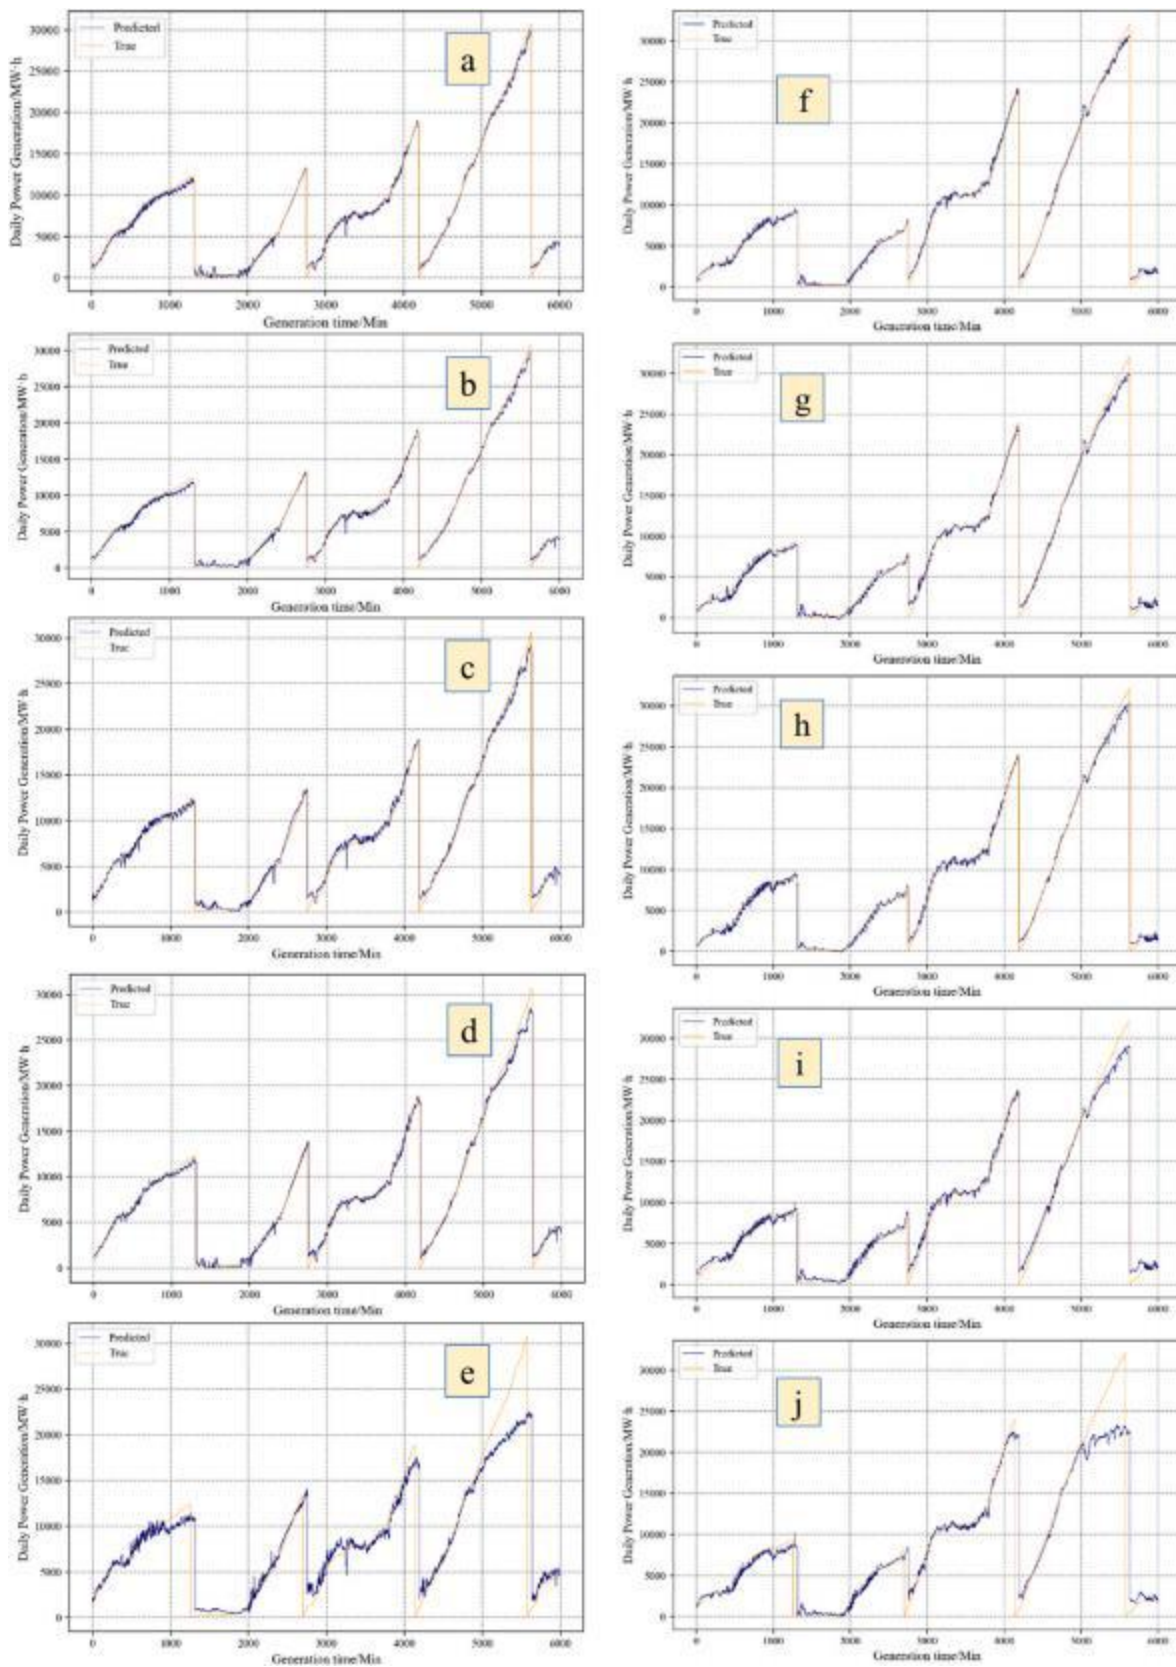


图8. 海上风力涡轮机 (OWT) /OWT1: (a)–(e); OWT8: (f)–(j)。

表5  
不同预测时间步长的评价指标。

海上风力涡轮机1				
Timestep	RMSE	MAPE	R-Square/%	MAE
1 min	572.33	12.167	99.2	267.696
2 min	815.29	15.35	98.6	334.48
5 min	1216.02	13.55	96	439.82
10 min	1613.39	30.35	94	456.17
60 min	3571	18	72.7	1524.42

海上风力涡轮机8				
Timestep	RMSE	MAPE	R-Square/%	MAE
1 min	667.5	12.74	99.3	314.77
2 min	918.33	70.49	98.7	435.91
5 min	1272.45	13.78	97	432.87
10 min	1770.42	17.79	95	666.43
60 min	3708.94	19.79	79	1408.37

选取时间序列预测的学习模型，包括RNN、GRU、LSTM、RNN-AM、GRU-AM、LSTM-AM、CNN-RNN、CNN-GRU、CNN-LSTM、CNN-RNN-AM和CNN-GRU-AM进行比较，计算两种情况。

表6提供了四种功率预测误差的概述，清楚地表明CNN-LSTM-AM模型在性能方面优于其他模型。表7进一步证实了这种一致性，其中给出了准确性指标。与CNN-GRU-AM相比，具有相似结构的模型CNN-LSTM-AM有了显著的改进。在案例1中，通过四个指标衡量，CNN-LSTM-AM的准确性分别比CNN-GRU-AM高出11.7%、9.46%、7.4%和13.77%。同样，在病例2中，CNN-LSTM-AM的改善率分别为9.12%、8.81%、11.41%和2.74%。

图. 11和12显示了两种情况下四种误差的分布。一般来说，将CNN和AM纳入时间序列预测模型会导致RMSE、MAPE和MAE值的降低。这表明，使用单一模型进行特征提取不如使用混合模型有效。

即使增加了数据量或超参数，即使要进一步提高预测精度也具有挑战性

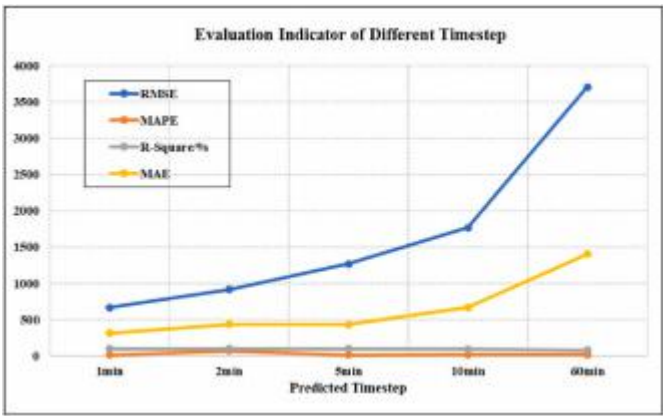


图10. 预测时间步长的评价指标（OWT8）。

表6  
案例1中深度学习模型的误差比较。

	RMSE	MAPE	R-型-正方形/%MAE	
递归神经网络	170.29	35.83	75	119.98
格勒乌	161.34	32.82	78	108.45
激光扫描跟踪法	159.41	34.15	78	106.98
递归-上午神经网络	158.12	40.41	79	102.04
格鲁阿姆	161.77	45.59	77.8	106.27
lstm-am	160.92	34.81	78	107.21
中心 - RNN 体	160.23	33.42	78.2	105.76
克宁格鲁	163.85	33.96	77	113.53
cnn-lstm	157.67	35.56	79	102.25
中心-rnnam 体	159.28	40.54	79	109.12
cnn-gru-am	170.17	34.54	75	121.91
<b>CNNlstm-am</b>	<b>150.24</b>	<b>31.27</b>	<b>81</b>	<b>105.12</b>

调解这种限制可能源于缺乏关键的气象数据。本研究特别考虑了传动链中的机械能传递过程及其向电能的转化。因此，来自风能捕获和初始转换阶段的数据没有被整合到预测模型中。

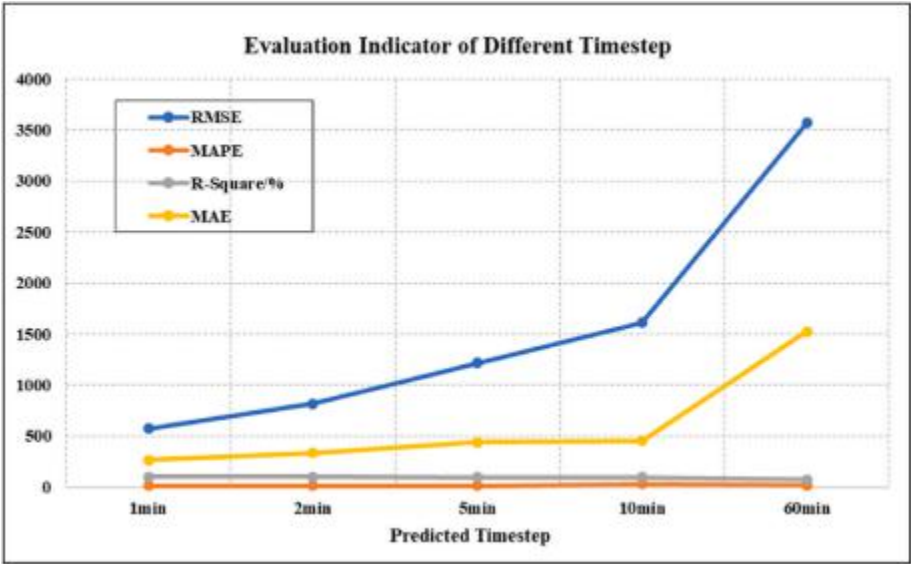


图9. 预测时间步长的评价指标（OWT1）。

表7  
案例2中深度学习模型的误差比较。

RMSE	MAPE	R型-正方形/%MAE		
递归神经网络	171.46	35.66	76	117.61
格勒乌	160.33	32.43	78	108.08
激光扫描跟踪法	159.06	34.11	79	106.42
递归-上午神经网络	159.32	40.54	78.7	105.69
格鲁阿姆	161.47	45.31	77.6	106.72
lstm-am	160.51	34.58	78.4	107.38
中心-RNN体	160.27	33.4	78.2	103.12
克宁格鲁	162.41	33.94	77.9	110.14
cnn-lstm	157.64	35.46	79.4	106.54
中心-rnnam体	159.05	32.71	79.6	107.64
cnn-gru-am	164.56	33.16	75.4	104.22
CNNlstm-am	149.56	30.24	84	101.36

3.4. 传感器灵敏度分析

传感器灵敏度分析是指导数据集构建和提高预测模型精度的关键。功率预测中的传感器权重由误差变化率来测量，定义为

$$\text{错误变化率}_x = \frac{\text{预测误差}_{\text{所有}} - \text{预测误差}_{\text{全部}}}{\text{预测误差}_{\text{所有}}} \quad (19)$$

错误变化率<sub>x</sub>表示传感器x的误差变化率，预测误差<sub>所有</sub>表示所有传感器的预测误差和预测误差<sub>全部</sub>表示屏蔽单个传感器x后的预测误差。

当错误变化率大于0时，表示误差有所下降  
在误差中不考虑传感器；绝对值越高，负灵敏度越高。相反，当错误变化率小于0时，表示误差增加

考虑到传感器；绝对值越高，正灵敏度越高。表8显示了陆上风力涡轮机的13个传感器的误差变化率。图13说明了陆上风力涡轮机的传感器之间的误差变化率的比较结果。

同样，表9给出了owt中12个传感器的错误变化率。图14提供了一个解释性的可视化，说明了在owt的传感器之间的错误变化率的比较结果。

值得注意的是，对于陆上风力涡轮机，发电机扭矩的MAPE显示出与其他12个传感器通道相反的趋势，错误率为-270.004%。这表明，从原传感器组中去掉发电机扭矩，显著降低了风能预测模型的精度。相比之下，其他12个传感器的错误变化率均在零以上，每个都超过5%。这表明，将这些传感器排除在风能预测过程之外将提高预测的准确性，因为来自这些通道的数据往往会污染训练数据集。发电机绕组最高温度的MAE变化率略有下降，但仍低于零。发电机冷却水的温度明显突出，MAE和RMSE均急剧下降，成为预测模型中第二关键的传感器。最后，折线图中RMSE和r平方的适度趋势突出了其余陆上传感器的相对不敏感度。

当分析表9和图时。14总的来说，很明显，RMSE和MAPE的错误变化率非常相似。值得注意的是，轮毂和变速箱高速轴的尾部温度都有大幅下降。这一观察结果强烈表明，这两个传感器通道在确保准确的海上风能预测方面发挥着关键作用。

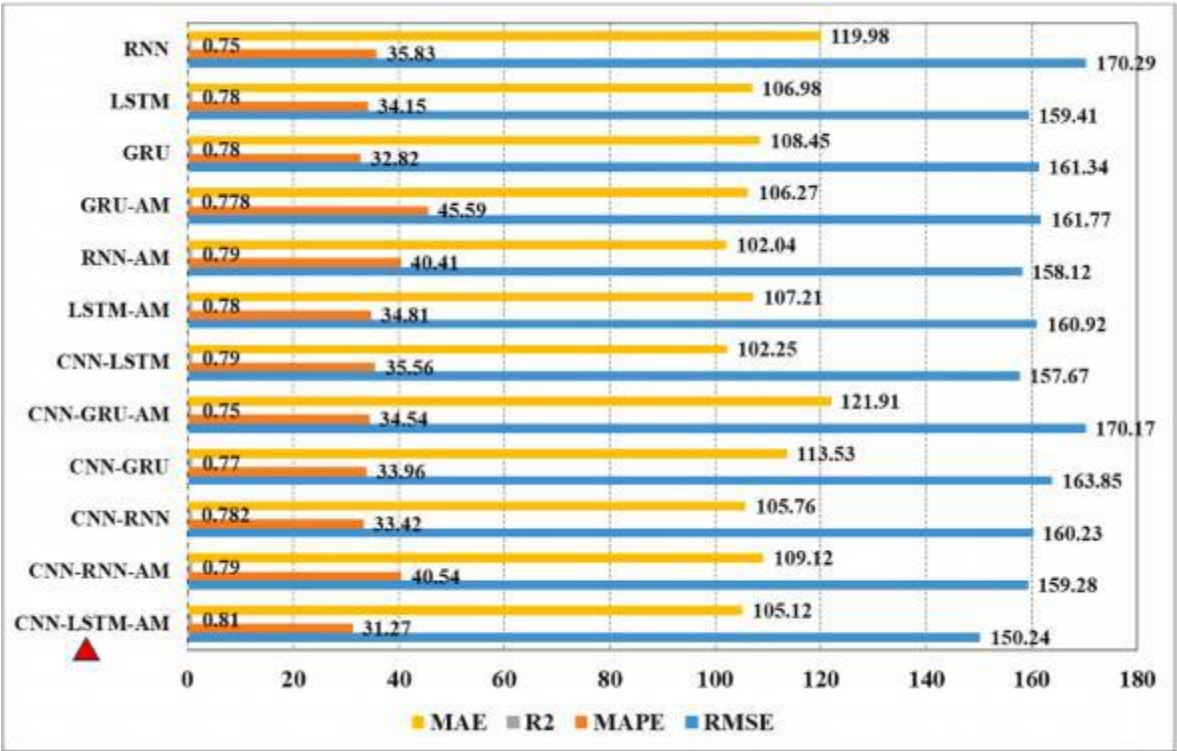


图11. 深度学习模型的误差比较：Case1/CNN-LSTM-AM：所提模型。




图12. 深度学习模型的误差比较: Case2/CNN-LSTM-AM: 所提模型。

表8  
陆上风力发电机组传感器的灵敏度。

传感器	人民币/%	磁带/%	R-Square/%	百分比
发电机转速	- 0.934	- 16.749	0.353	2.311
发电机绕组的最大温度	- 0.687	- 2.519	0.235	- 0.982
发电机绕组U1温度	- 0.139	- 4.015	0.118	3.904
发电机冷却水温度	- 2.754	- 14.089	1.058	- 2.277
发电机前轴承温度	- 1.089	- 9.313	0.470	0.170
发电机后轴承温度	- 0.225	- 3.135	0.118	3.833
发电机滑动环腔室温度	- 0.363	- 5.701	0.118	0.148
发电机扭矩	- 1.611	- 270.004	0.588	- 0.215
主轴承的前轴承温度	- 0.139	- 1.510	0.118	2.784
主轴承的后轴承温度	- 0.604	- 6.344	0.235	4.397
轴制动器液压	- 0.442	- 1.556	0.000	3.649
变流器内部温度	- 1.067	- 7.164	0.470	5.300
变流器内部的直流电压	0.142	- 8.699	0.000	4.093

5.3个讨论

本案例研究表明，多传感器融合模型通过合并来自各种机械部件和电子机械设备的传感器数据，多传感器融合模型解决了气象传感器故障或数据丢失导致的风力预测性能次优问题。此外，CNN-LSTM-AM算法还证明了其准确预测风力发电的能力。比较结果表明，CNN-LSTM-AM的性能优于其他深度挖掘方法及其组合。确定了多个传感器对风力发电能力预测的灵敏度，并量化了不同传感器类型对预测精度的影响。这允许为新的预测场景快速提供一个传感器类型选择方案。

然而，在未来的研究中，有一些潜在的问题需要进一步的研究。目前，风力发电的预测结果专门用于传感器的灵敏度分析。这意味着这些预测尚未被重新整合到模型优化的努力中。该模型的参数及其预测输出可以作为参数优化模型的输入。通过连续几轮优化，可以识别参数组合，导致最低的预测误差，从而提高模型的预测精度。因此，该模型的重新优化已经成为后续研究的一个关键领域。






图13. 陆上风机传感器的误差变化率。

表9  
OWT传感器的灵敏度。

传感器	人民币/%	磁带/%	R-Square/%	百分比
转子转速	33.553	33.673	57.786	33.551
集线器温度	- 25.125	- 25.000	- 58.522	- 24.948
齿轮箱高速轴的前端温度	33.786	33.673	58.105	33.753
变速箱高速轴尾部温度	- 17.806	- 18.367	- 40.126	- 17.977
齿轮箱油池温度	4.119	3.571	8.350	3.839
齿轮箱进口油温度	25.541	26.020	46.106	25.932
齿轮箱进口压力	30.846	30.612	53.988	30.870
齿轮箱油泵出口压力	27.034	26.531	48.382	26.817
发电机绕组U1温度	- 2.294	- 2.551	- 4.801	- 2.401
发电机冷却水温度	15.052	14.796	28.806	15.001
发电机前轴承温度	29.840	30.102	52.538	29.885
发电机后轴承温度	61.555	62.245	88.178	62.214




图14. 陆上风机传感器的误差变化率。

## 4. 结论

本文介绍了一种基于多传感器融合和CNN-LSTM-AM算法的风能预测框架。通过将多传感器与CNC-LSTM N-AM算法的融合, 在没有气象数据的情况下, 利用多个机电设备传感器实现了另一种风能预测方法。训练数据集的自动分区, 由时间步长参数化支持, 允许仅通过参数调整在同一数据集上运行多个时间步长预测。通过计算四个评价指标的误差变化率来量化传感器的灵敏度。研究结论: (i) 风力发电功率的预测结果表明, 多传感器融合模型在低发电功率的预测区间方面表现更好, 精度更高。(ii) 通过可变预测时间步长参数化, 在同一数据集上成功地进行了多个时间步长预测。前四种时间步长的准确率相对较高, 并在预测60 min后开始显著下降。(iii) 与CNN-GRU-AM相比, CNN-LSTM-AM的准确率分别提高了11.7%、9.46%、7.4%和13.77%, 病例2分别提高了9.12%、8.81%、11.41%和2.74%。(iv) 传感器灵敏度分析结果表明, 发电机转矩是风能预测模型中最敏感的传感器, 其次是发电机冷却水温度, 是预测模型中第二重要的传感器。

## 信誉良好的作者贡献声明

孙宇宇: 写作-审查与编辑、写作-原稿、验证、软件、方法、调查、正式分析、数据整理、概念化。周启博: 写作-初稿、资源、项目管理、方法学、调查、资金获取、正式分析。李孙: 写作-原稿、资源、项目管理、调查、资金获取、正式分析。孙丽平: 写作-审查与编辑、验证、监督、方法学、调查、资金获取。继川康: 写作-审查与编辑、验证、监督、项目管理、方法、调查、资金获取、正式分析。李贺宏: 写作-审查与编辑、可视化、验证、监督、资源、项目管理、方法、调查、资金获取、概念化。

## 相互竞争的利益的声明

作者声明, 他们没有已知的相互竞争的经济利益或个人关系, 这可能会影响本文报告的工作。

## 数据可用性

作者没有共享数据的许可。

## 确认信息

本研究由国家自然科学基金资助项目(No. 52101305和72301299)和Marie Skłodowska-Curie博士后奖学金(编号: 1. EPSRC EP/Z001501/1)。

## 参考文献

阿克曼, T., 斯德尔, L., 2000年。风能技术及现状。续订。维持。能量Rev. 4 (4), 315–374。  
大卫·巴塞洛缪, 1971年。时间序列分析、预测和控制。奥珀。物品Q.199–201。  
伯德, L., 卢, D., 米利根, M., 等人, 2016年。风能和太阳能的削减: 对国际经验的回顾。续订。维持。能量Rev. 65, 577–586。

科斯塔 A., 克雷波 A., 纳瓦罗, J., 等人, 2008年。回顾一下风的年轻历史  
功率短期预测。续订。维持。能量Rev. 12 (6), 1725–1744。委员会GWE, 2023年。2023年全球风报告。可以在: [https://gwec.net/wp-content/uploads/2023/04/GWEC-2023\\_interactive.pdf](https://gwec.net/wp-content/uploads/2023/04/GWEC-2023_interactive.pdf)。  
多纳迪奥, L., 方, J., 阿格尔港, F., 2021年。数值天气预报和人工智能耦合。能量14 (2), 338。  
艾弗利, M., 莱希, P. G., Marvuglia, A., 等人, 2012。风力发电能力预测的现有方法和研究进展。续订。维持。能量37 (1), 1–8。  
格雷夫斯, A., 施米德胡伯, J., 2005。基于双向LSTM神经网络结构的框架式音素分类。神经网络18 (5–6), 602–610。  
格雷夫, 克, 斯里瓦斯塔瓦, R. K., Koutnik, J., 等人, 2015年。LSTM: 搜索空间奥德赛。神经网络和学习系统10, 8。  
Hanifi, S., 刘, X., 林, Z., 等人, 2020年。对风力发电预测的关键回顾方法, 过去, 现在和未来。能量13 (15), 3764。  
哈尼菲, S., 扎雷-贝塔什, H., 坎卡拉诺, A., 等人, 2023年。基于WPD的海上风电预测和优化的深度学习方法。续订。能源218、119241。  
海达里, A., 马吉迪, 内兹哈德, M., 内萨特, M., 等人, 2021年。模糊GMDH神经网络与灰狼优化相结合的基于SCADA数据的风力发电预测应用。能量14 (12), 3459。  
霍克雷特, 尤尔根, 1997年。长期记忆。神经成分。9 (8), 1735–1780。  
胡, s., 翔, Y., 张, H., 等, 2021。综合空间相关性和修正数值天气预报的风力发电混合预报方法。应用程序。能源293、116951。  
Jung, J., 布罗德沃特, R. P., 2014。风速和电力预测的现状和未来进展。续订。维持。能量Rev. 31, 762–777。  
Jung, S., Kwon, S. D., 2013。神经网络中的加权误差函数用于改进风能估计。应用程序。能源111、778–790。  
Jyothi, N., 饶, P. V. R., 2016。利用自适应小波神经网络进行极短时间的风力发电预测。见: 2016年两年一次的电力和能源系统国际会议论文集: 走向可持续能源, PESTSE 2016年, 印度班加罗尔。IEEE, 皮斯卡塔韦, 新泽西州, 美国, 页。21–23。  
康, J., 孙, L., 圭德斯·苏亚雷斯, C., 2019年。浮动式海上风力涡轮机的故障树分析。续订。能源133、1455e1467。  
基斯瓦里, A., 林, Z., 刘, X., 2021年。风力发电预测——一种数据驱动的方法和门控递归神经网络。续订。能源163、1895–1909。  
兰德伯格, 迈勒普, L., 拉斯曼, O., 等, 2003年。风力资源估算-概述。《风能: 一本关于风能转换技术的进展与应用的国际杂志》6 (3), 261–271。  
勒村, Y., 博都, L., Bengio, Y., 等人, 1998年。基于梯度的学习应用于文献识别过程IEEE 86 (11), 2278–2324。  
李, h., 圭德斯·苏亚雷斯, C., 2022年。对浮动式海上风力涡轮机的故障率和可靠性进行评估。信保。雕刻西斯特。Saf. 228, 108777。  
李, h., 圭德斯·苏亚雷斯, C., 黄, 洪中, 2020年。利用贝叶斯网络对浮式海上风力涡轮机的可靠性分析。洋雕刻217, 107827。  
李, H., 迪亚兹, H., 圭德斯·苏亚雷斯, C., 2021a。浮动海上风力机支架结构的失效模式及效果分析。续订。能源164、133–145。  
李, H., 迪亚兹, H., 圭德斯·苏亚雷斯, C., 2021b。采用AHP-FMEA方法对浮动式海上风力涡轮机进行失效分析。洋雕刻234, 109261。  
李, J., 等, 卡罗尔, 等, 等, R., 2022a。一种考虑不确定性的海上风电场多目标维护策略优化框架。应用程序。能源321、119284。  
李, h., 黄, 成庚, 圭德斯·苏亚雷斯, C., 2022b。对浮动海上风力涡轮机的实时检查和机会维护策略。洋雕刻256, 111433。  
李, H., 彭, W., 黄, C. G., 圭德斯·苏亚雷斯, c, 2022c。故障率评估  
陆上和浮动的海上风力涡轮机。J. 破坏科学。雕刻10 (12), 1965。  
林, 刘, x., 2020。基于高的海上风力发电机风力预测  
频率SCADA数据和深度学习神经网络。能源201、117693。陆, W., 李, J., 王, J., 等人, 2021。一种CNN-BiLSTM-AM的股票价格计算方法  
预测神经成分。应用程序。33, 4741–4753。  
马内罗, J., Bjar, J., 科特, 美国, 2018。基于神经网络的风能预测: 一篇文献综述。压缩。西斯特。22 (4), 1085–1098。  
麦克多纳, S., 艾哈迈德, S., 德斯蒙德, C., 等人, 2020年。来自海上风能的氢气: 投资者对混合动力系统盈利能力的看法, 包括削减开支。应用程序。能源265、114732。  
姆尼赫, 诉, 海斯, N., 格雷夫斯, A., 2014年。视觉注意的循环模型。Adv. 神经Inf. 过程。西斯特。27。  
Neshat, M., Nezhad, M. M., 阿巴斯内贾德, E., 等人, 2021年。基于深度学习  
短期风速预测的演化模型: 利尔格隆德海上风电场的一个案例研究。能量转换器。马纳格。236, 114002。  
Neshat, M., Nezhad, M. M., 米尔贾利利, S. 等, 2022。四元数卷积长短期记忆神经模型与自适应分解方法的风速预测: 北爱琴海群岛的案例研究。能量转换器。马纳格。259, 115590。  
Nezhad, M. M., Neshat, M., Sylaios, G., 等人, 2024年。海洋能源数字化数字双胞胎的方法。续订。维持。能量Rev. 191, 114065。  
钱, z., 裴, Y., 扎雷普尔, h., 等人, 2019年。基于分解的混合模型对风能预测应用的综述与讨论。应用程序。能源235、939–953。  
奎雷希, A. S., 可汗, A., 扎米尔公司, A., 等人, 2017年。基于深度神经网络的元回归和迁移学习的风能预测。应用程序。软组合。58, 742–755。  
Raza, M. Q., 科斯拉维, A., 2015。基于人工智能的智能电网和建筑物负荷需求预测技术综述。续订。维持。能量Rev. 50, 1352–1372。

孙, Y., 康, J., 孙, L., 等人, 2022年。基于长短期存储网络的海上风力机状态维护。过程在。机械。雕刻0 J. 风险可靠性。236 (4), 542 - 553.

孙, Y., 李, H., 孙, L., 等人, 2023年。浮式海上风机与相关故障的故障分析。信保。雕刻西斯特。Saf. 238, 109485.

托恩, 布罗韦尔, J., 2022年。回顾一下非常短期的风能和太阳能发电预测。续订。维持。能量Rev. 153, 111758.

瓦斯瓦尼, A., 谢泽尔, N., Parmar, N., 等人, 2017年。你所需要的就是注意力。Adv. 神经Inf. 过程。西斯特。30.

王, H., 韩, S., 刘, Y., 等, 2019。该算法中的序列传输校正算法数值天气预报风速及其在风力发电预报系统中的应用。应用程序。能量237, 1-10.

项, L., 王, P., 杨, X., 等人, 2021年。基于CNN和LSTM的SCADA数据分析的风力机故障检测。测量175、109094。

邢, 他, Y., 2023。基于叠加深度学习模型的多模态多步风电预测。续订。能源215、118991。

亚蒂亚纳, E., 拉贾卡鲁纳, S., 高希, A., 2017。利用ARIMA模式对风力发电能力进行风速和方向预测。2017年澳大利亚大学电力工程会议 (AUPEC)。IEEE, pp. 1 - 6.

余, 张, Z, 李, X, 等, 2020。海上应用的叠加图神经网络风力发电预测。未来的发电机。压缩。西斯特。113, 145 - 157. 扎尔, S., Ayati, M., 2021年。风力发电机的同时故障诊断多通道卷积神经网络。ISA跨。108, 230 - 239.

张, w., 林, z., 刘, x., 2022年。短期海上风力发电预测——一种基于离散小波变换 (DWT)、季节自回归综合移动平均数 (SARIMA) 和基于深度学习的长短期记忆 (LSTM) 的混合模型。续订。能源185、611-628。